Spiking Neural Network チュートリアル

京都大学大学院情報学研究科　D1 羽原丈博

自己紹介

羽原 丈博（はばら たけひろ）

所属

京都大学大学院情報学研究科 通信情報システム
集積システム工学講座 D1

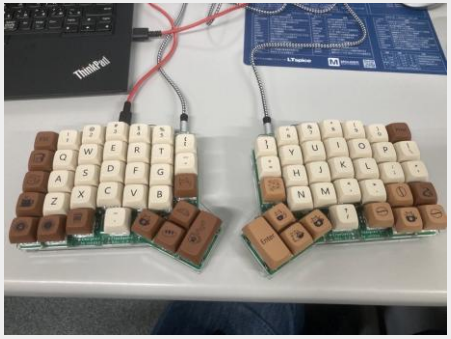
趣味

ものづくり（料理やプログラミングなど）
ゲーム全般（アナログもディジタルも）



研究テーマ

✓スパイキングニューラルネットワークの
高速・低消費エネルギ推論
✓人流解析、スタイル変換などCV系



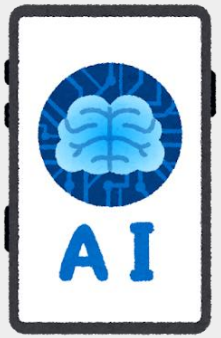
目次

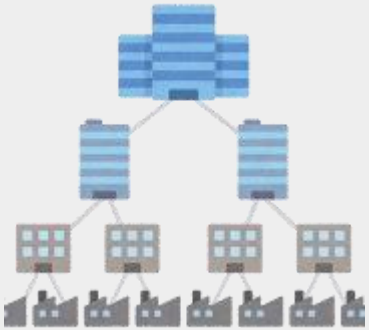
1. スパイキングニューラルネットワークの現状
   A) スパイキングニューラルネットワークについて
   B) 事例：物体検出
   C) 事例：拡散モデル
   D) 事例：物体追跡システム
   E) その他事例
2. 課題と解決への取り組み
3. まとめ

Spiking Neural Networkってなに？

低消費電力で推論可能でエッジデバイス上での運用を期待されているニューラルネットワークモデル

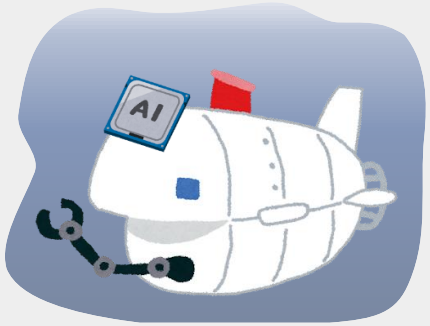
誰でもどこでも利用できる高度な認知処理システムの実現





低コストで利用







極地での利用

Artificial Neural Network (ANN)

深層学習で一般的に用いられるネットワークモデル

✓ 学習が容易で，様々なタスクに応用可能



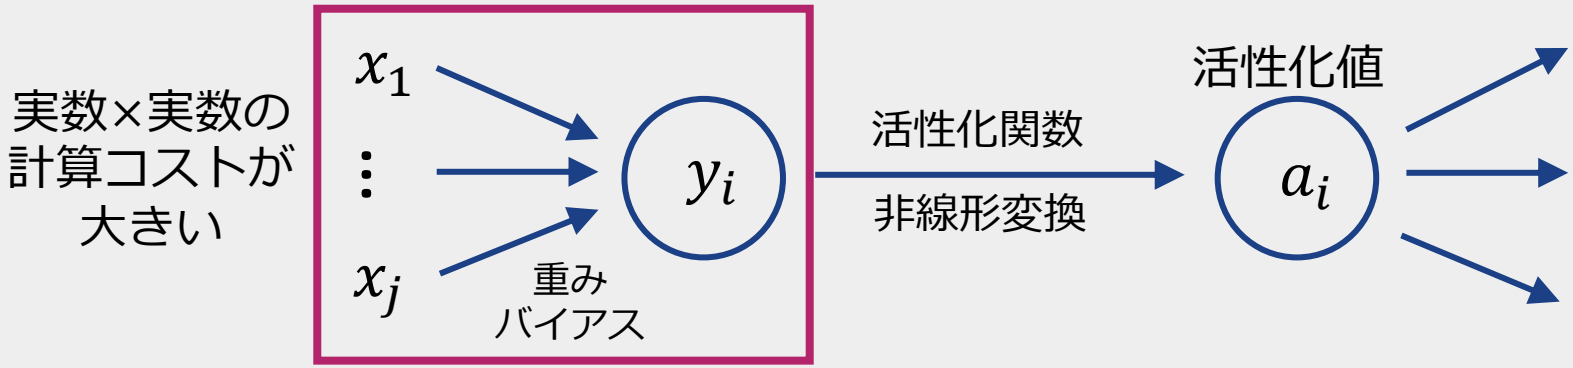
MidJourneyのような拡散モデルによる画像生成



ChatGPTのような大規模言語モデルによる自然言語処理

✓ 実数で情報伝達しており，高消費電力

GPUの消費電力はA100で400W，エッジ向けのJetson TX2は7.5～10W

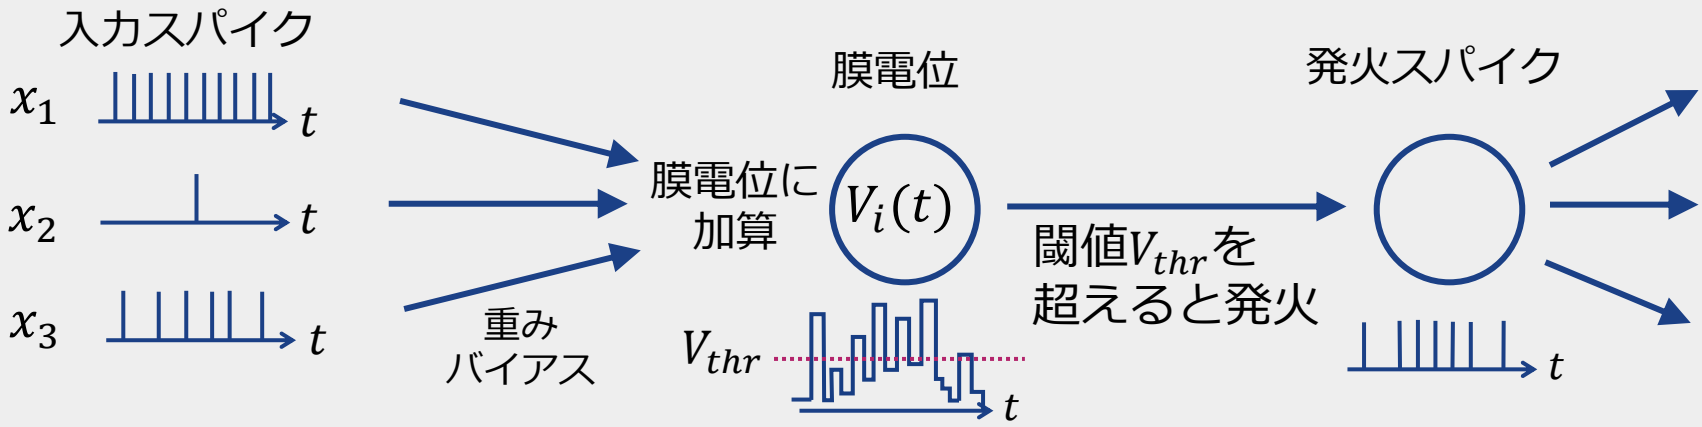


ANNのニューロンにおける推論

Spiking Neural Network (SNN)

生体の神経活動を模したネットワークモデル

✓スパイクの発火頻度で情報伝達

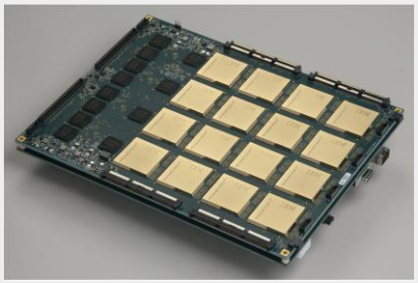


✓ スパース且つイベント駆動で低消費電力

SNN専用のニューロモーフィックチップが開発

IBMのTrueNorthは65mWで動作可能

VGG: 16.2倍, ResNet: 13.3倍の電力効率

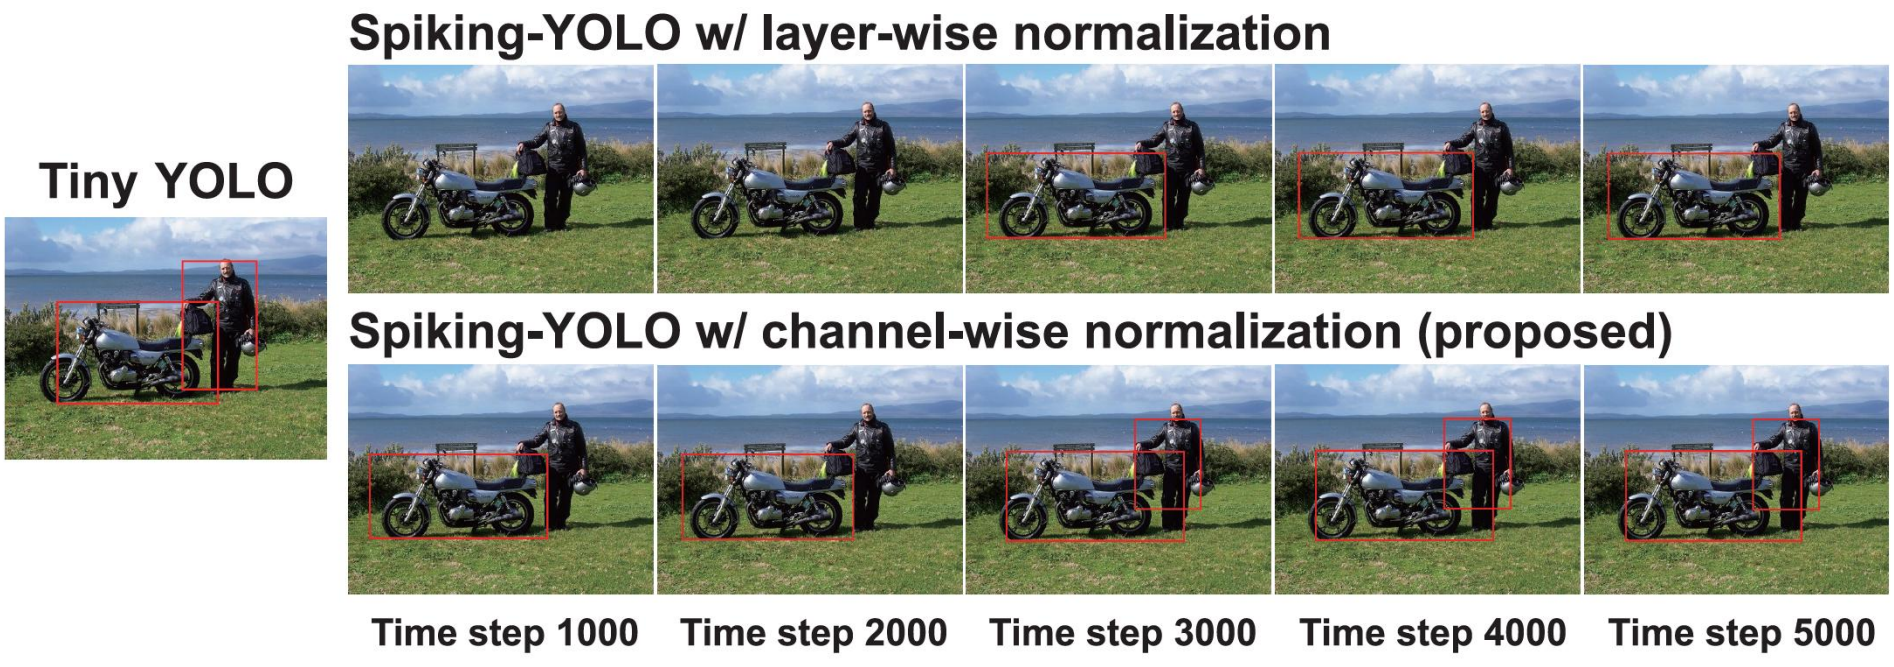


TrueNorthの外観

事例：物体検出

SNNで実装したYOLOによる物体検出

四角のバウンディングボックスとして画像中の物体を見つけ、クラス分類を行う



Kim, Seijoon & Park, Seongsik & Na, Byunggook & Yoon, Sungroh. (2020). Spiking-YOLO: Spiking Neural Network for Energy-Efficient Object Detection. Proceedings of the AAAI Conference on Artificial Intelligence. 34. 11270-11277. 10.1609/aaai.v34i07.6787.

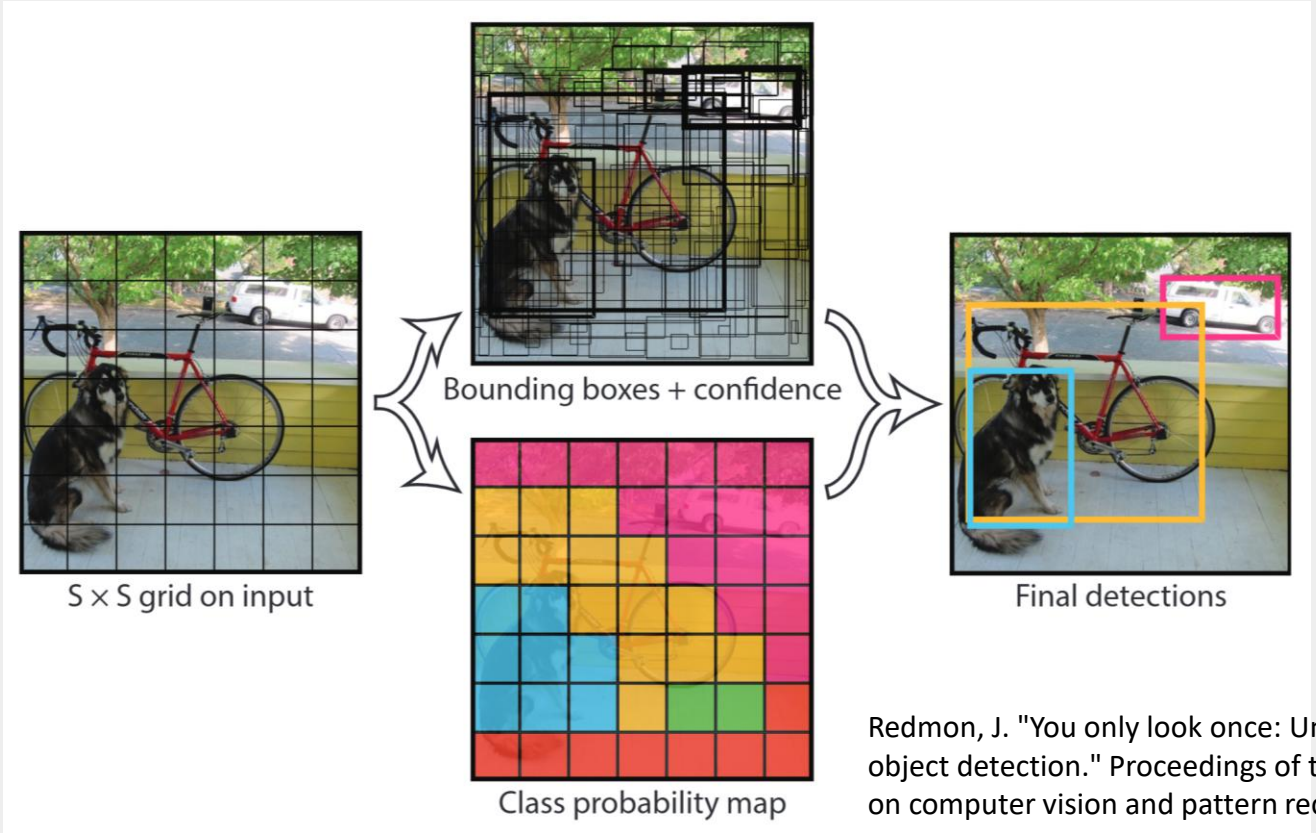
事例：物体検出

YOLO (ANN)

入力：画像

出力①：bounding boxesの中心座標、幅、高さ、信頼度

出力②：各グリッドにおけるクラスごとの分類確率



Redmon, J. "You only look once: Unified, real-time object detection." Proceedings of the IEEE conference on computer vision and pattern recognition. 2016.

事例：物体検出

Spiking YOLO

入力：同じ画像を時間方向に並べたもの
1タイムステップごとに1回入力する

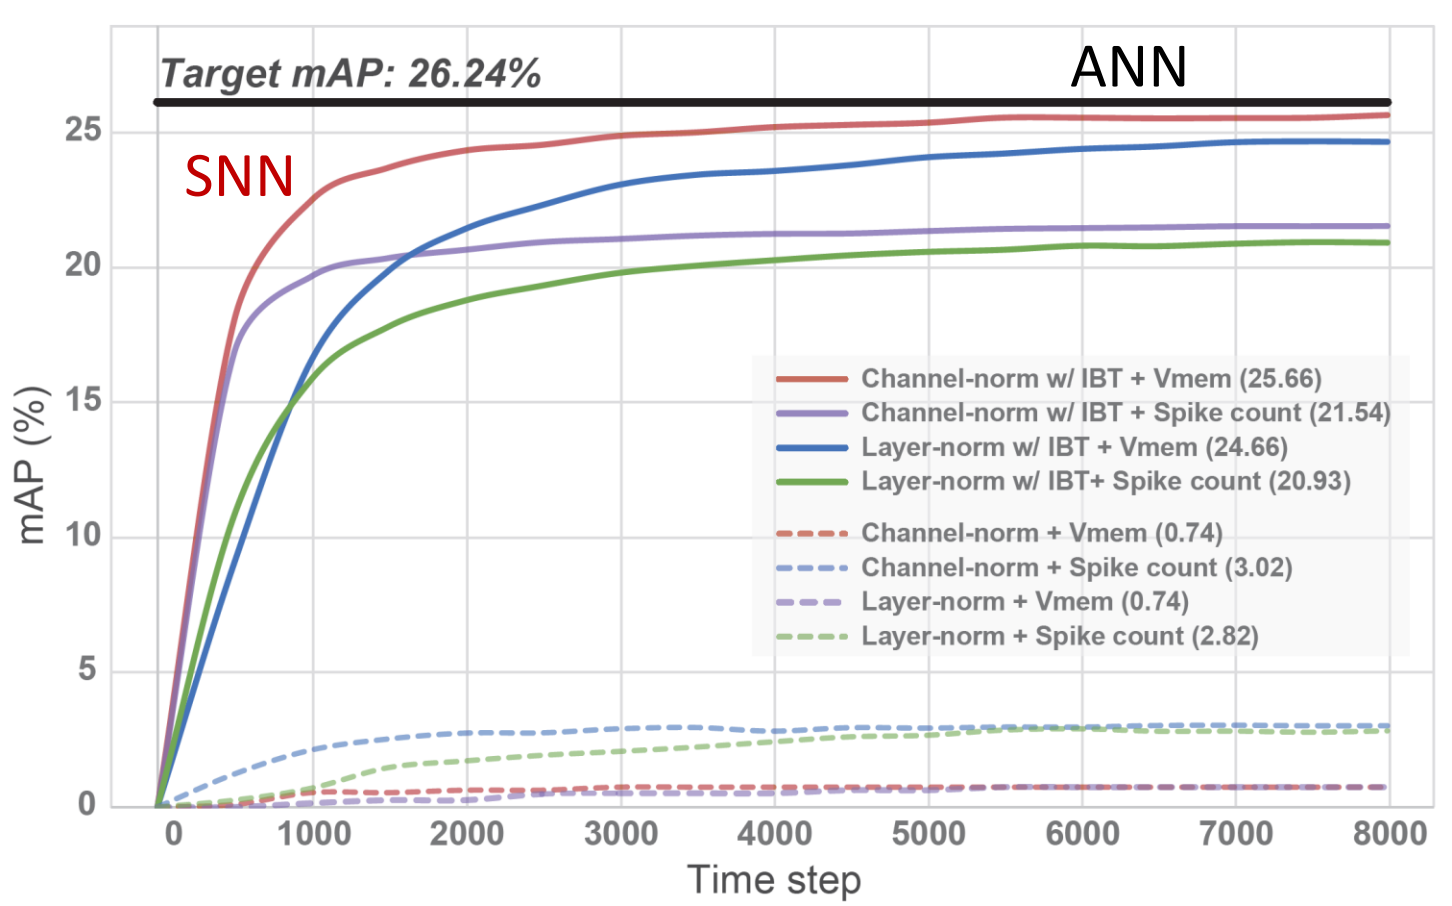
出力①：ニューロンの膜電位で表されるbounding boxesの中心座標、幅、高さ、信頼度

出力②：ニューロンの膜電位で表される各グリッドにおけるクラスごとの分類確率



事例：物体検出

4000タイムステップぐらい推論することでANNと同等の精度に達することが可能



MS COCOデータセットにおける結果

事例：物体検出

ANNに比べて消費エネルギを99.6%削減可能

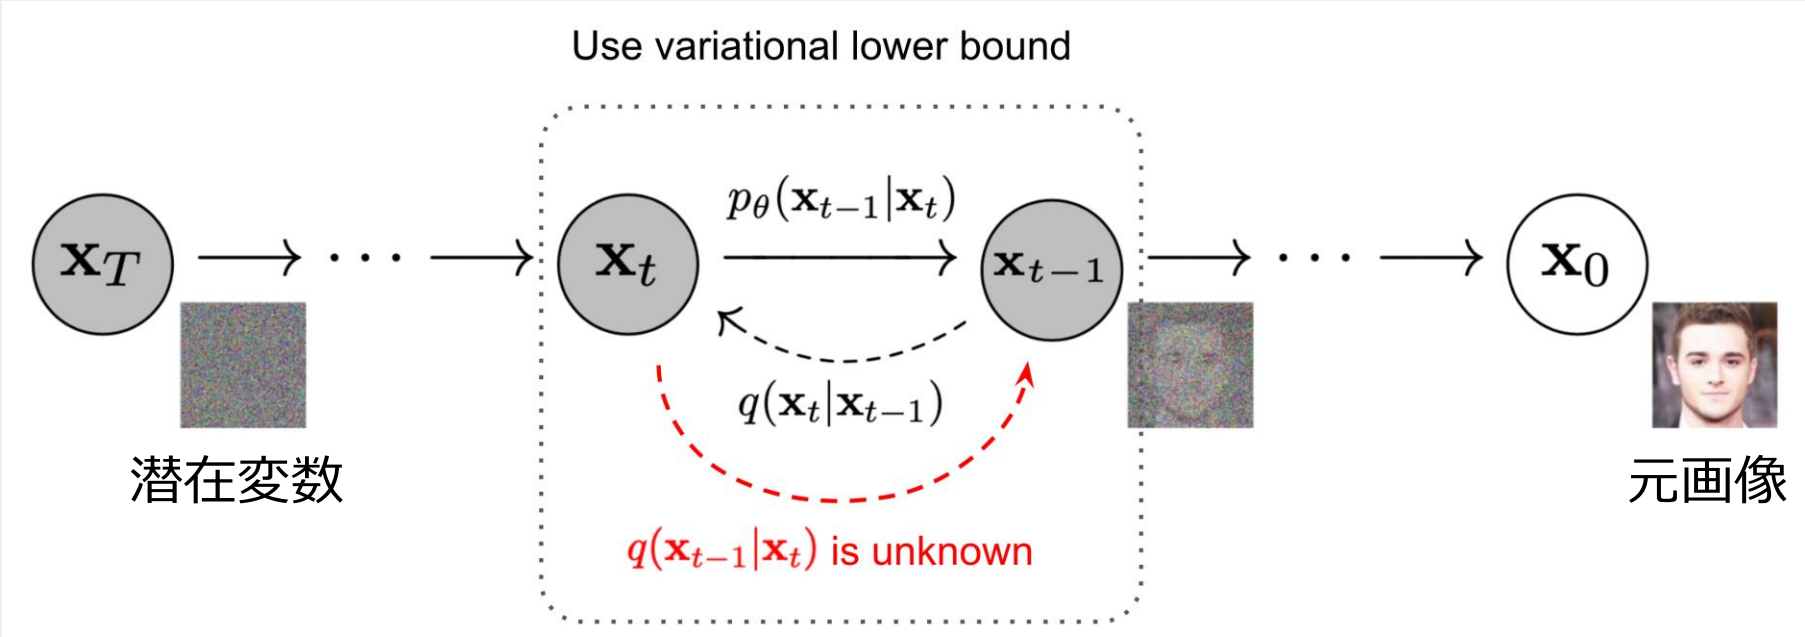
Tiny YOLO					
	Power (W)	GFLOPS	FLOPs		Energy (J)
	250	14,000	6.97E+09		0.12
Spiking-YOLO					
Norm. methods	GFLOPS / W	FLOPs	Power (W)	Time steps	Energy (J)
Layer	400	5.28E+07	1.320E-04	8,000	1.06E-03
Channel	400	4.90E+07	1.225E-04	**3,500**	**4.29E-04**

ANN: Titan V100で実行したときのパフォーマンス
SNN: TrueNorthで実行したときのパフォーマンス

事例：拡散モデル

SNNで実装した拡散モデルによる画像生成

拡散モデル：学習した確率分布から得たノイズを、潜在変数に加える過程を繰り返すことで画像を生成するモデル

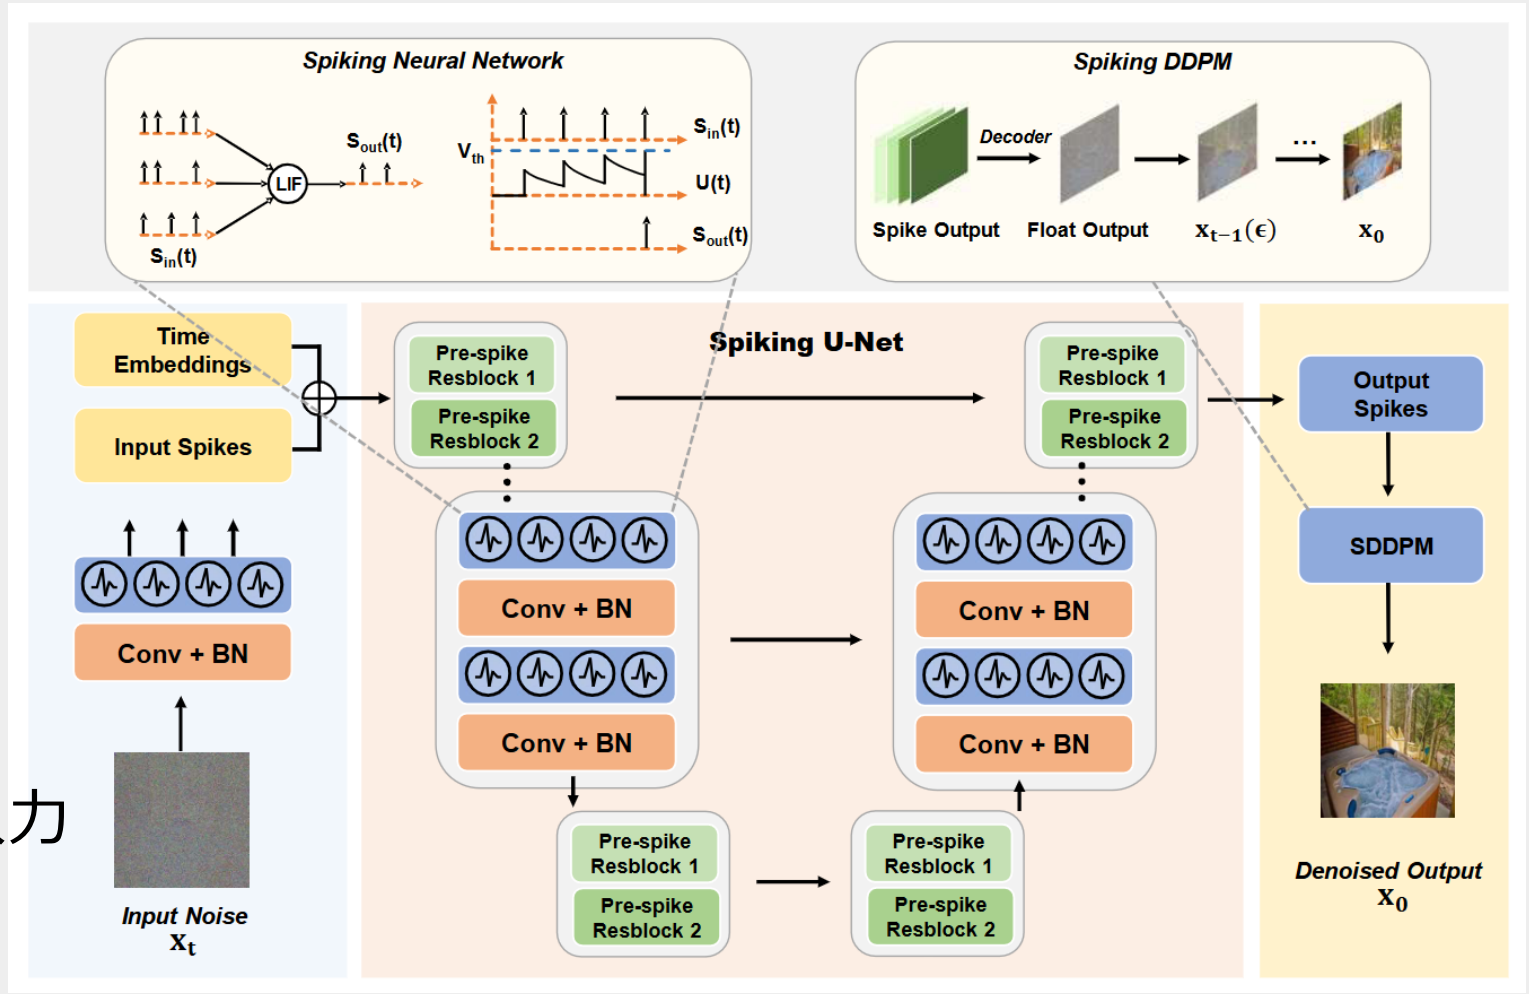


https://lilianweng.github.io/posts/2021-07-11-diffusion-models/

Jiahang, Cao & Hanzhong, Guo & Ziqing, Wang & Deming, Zhou & Hao, Cheng & Qiang, Zhang & Renjing, Xu. (2024). Spiking Diffusion Models. arXiv. 2408.16467.

事例：拡散モデル

出力されたスパイク列を元にノイズを生成



入力

Cao, J., Wang, Z., Guo, H., Cheng, H., Zhang, Q., & Xu, R. (2024). Spiking denoising diffusion probabilistic models. In Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (pp. 4912-4921).

事例：拡散モデル

生成結果



Fashion MNIST

MNIST

CIFAR-10

CelebA

LSUN-bed

事例：拡散モデル

定量的評価項目

FID：生成画像と元画像の特徴量の距離

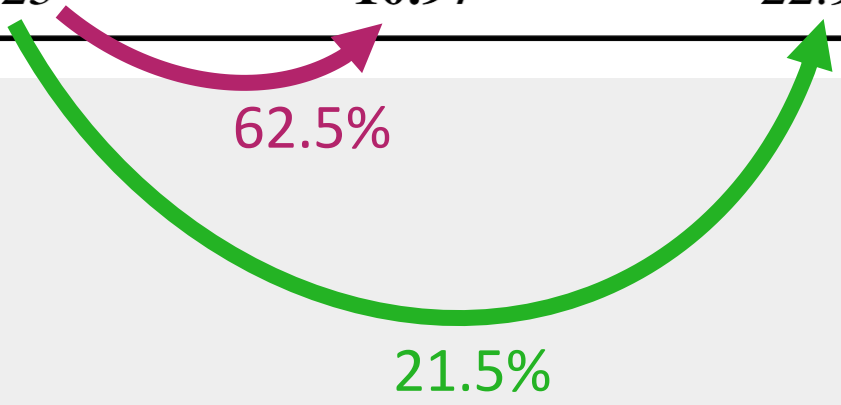
消費エネルギ：推論の演算数を元に算出

結果

✓ANNと同等のFIDで消費エネルギを62.5%削減可能

✓ANNよりもFIDが改善した場合でも21.5%削減可能

Model	DDPM-ANN	SDDPM-4T	SDDPM-8T
FID↓	19.04	18.57	**15.45**
Energy (mJ)↓	29.23	**10.97**	22.96



事例：物体追跡システム

SNNのアクセラレータとイベントカメラを用いて、卓球ボールを追跡し、ロボットで打ち返す研究

Related Work

Spiking Neural Network (SNN)

UNIVERSITÄT TÜBINGEN

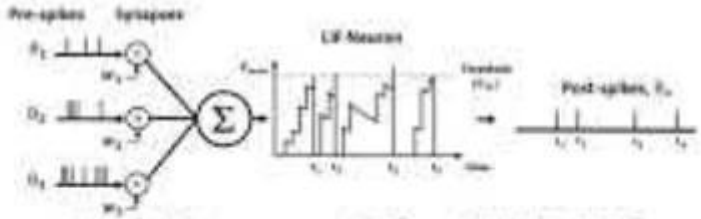


Figure: LIF neuron model [Lee, FNINS, 2020]

Background:

- SNNs model the spiking behavior of biological neurons more closely

Advantages:

- No multiplications needed (only additions) -> efficient implementations on hardware

Detection of Fast-Moving Objects with Neuromorphic Hardware — Andreas Ziegler et al. 3/5

Ziegler, A., Vetter, K., Gossard, T., Tebbe, J., Otte, S., & Zell, A. (2024). Detection of Fast-Moving Objects with Neuromorphic Hardware. arXiv preprint arXiv:2403.10677.

事例：物体追跡システム

イベントカメラ

ピクセルの輝度が大きく変化したことのみを情報として出力するカメラ



事例：物体追跡システム

イベントカメラ

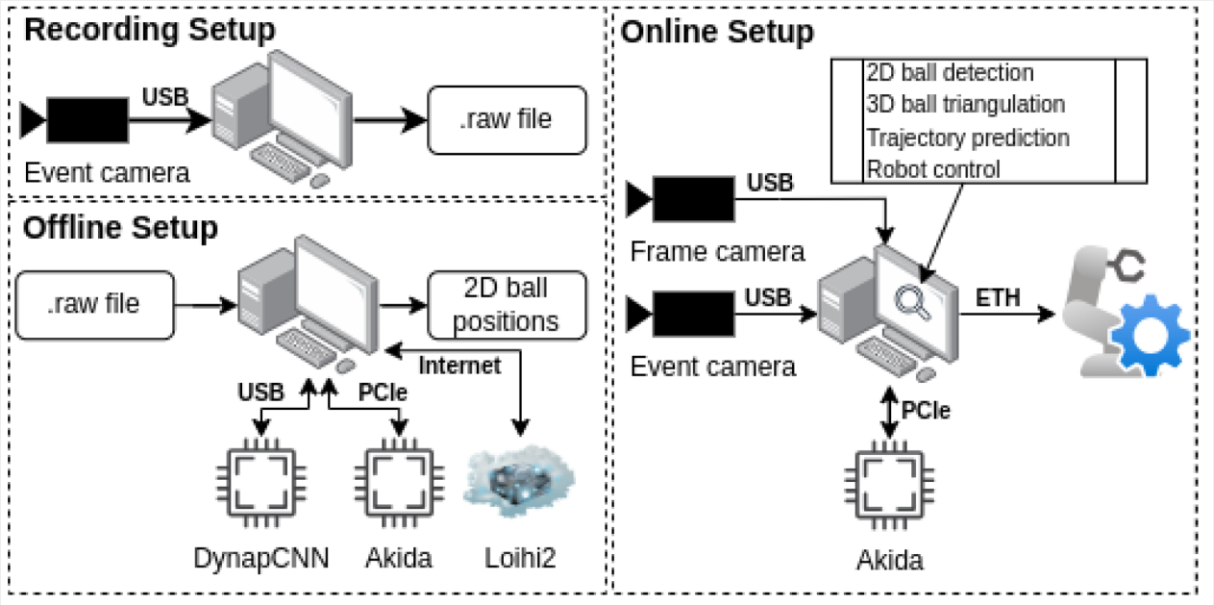
ピクセルの輝度が大きく変化したことのみを情報として出力するカメラ

- ✓ 高フレームレート
  - スポーツなどへの応用
- ✓ 低消費電力
  - ロボットやエッジデバイスへの応用
- ✓ 高ダイナミックレンジ
  - 自動運転や宇宙・深海探査など光環境が大きく変化する場所への応用
- ✓ 非同期的
  - スパイキングニューラルネットワークとの相性の良さ

事例：物体追跡システム

実験設定

- ✓Offline実験
  - 入力：イベントカメラの出力を1msの間積分したフレーム
  - 出力：そのフレーム内のうち卓球ボールの中心座標
- ✓Online実験
  - 入力：4つのフレームカメラと1つのイベントカメラ（1msでフレーム化）
  - 出力：ロボットの関節座標



事例：物体追跡システム

Offline実験

Error：追跡したボール座標のずれ

One forward pass：データ入力から座標出力までの時間

Inference time：ハードウェアで推論した時間

ハードウェア	Error [pixel]	One forward pass [ms]	Inference time [ms]
BrainChip Akida	1.44 ± 1.41	2.20 ± 0.35	0.89 ± 0.28
DynapCNN	1.59 ± 1.83	46.04 ± 21.38	0.82 ± 0.24
Loihi2	1.57 ± 1.55	1458.57 ± 230.50	0.62 ± 0.01

DynapCNNはUSB接続、Loihi2はクラウドサーバなので通信オーバーヘッドがあり、One forward passは大きい

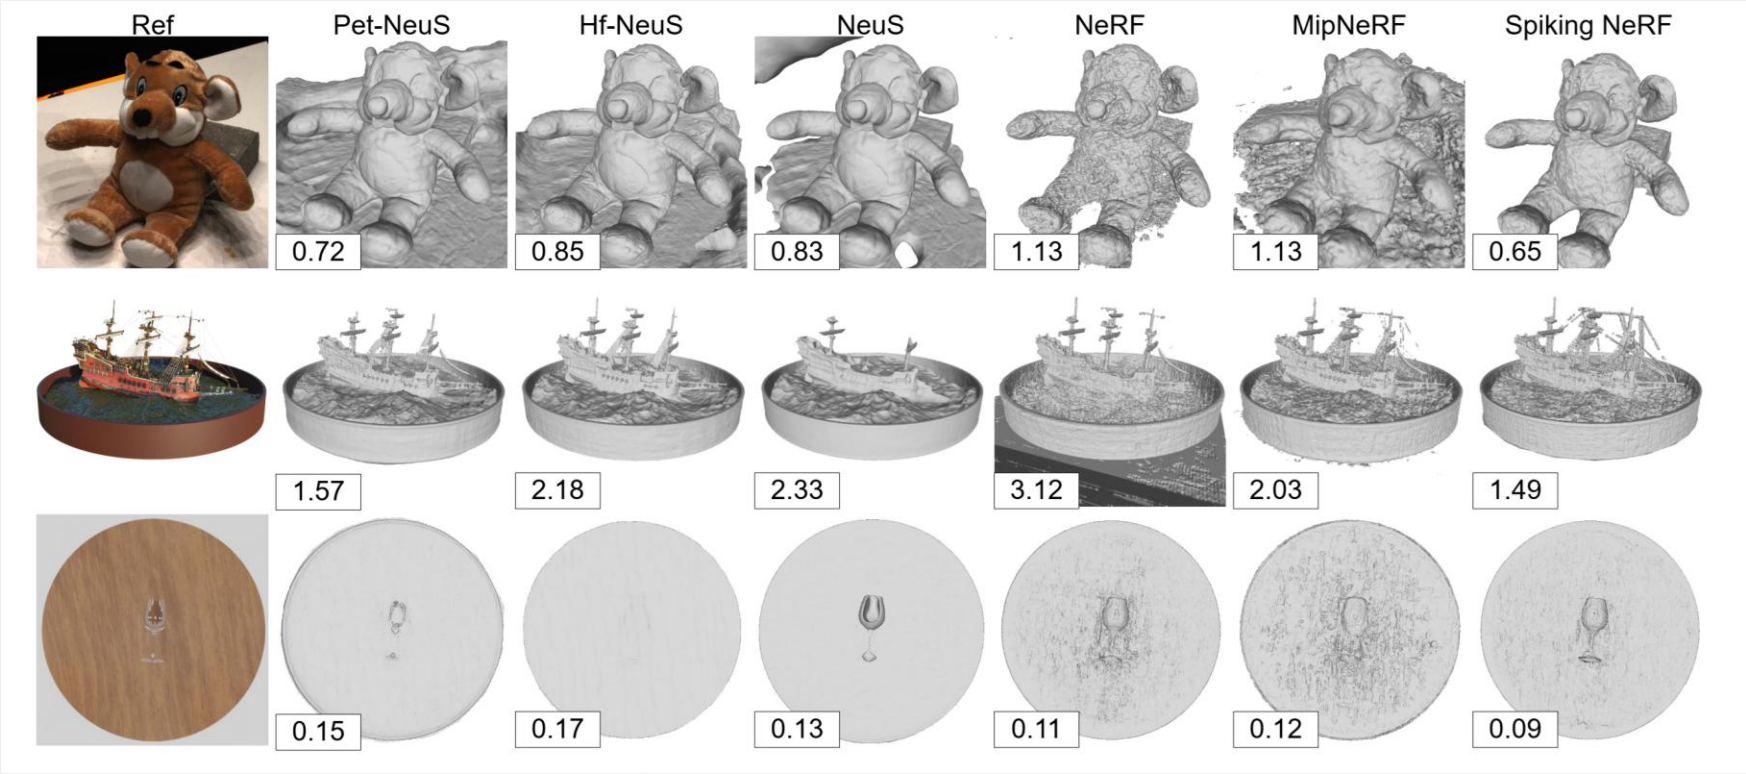
Offline実験

彼らの実験設定ではすべてのボールを打ち返すことが可能

その他事例

NeRF

従来のANNでは幾何学表現が連続であるため、空気と物体表面の界面が分離されない
そこで、SNNの非連続性を活用

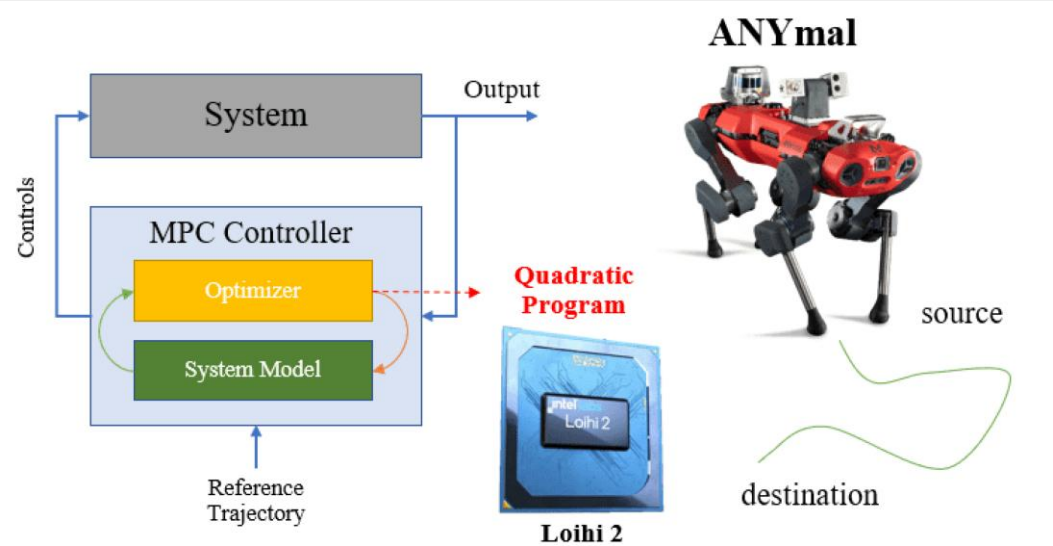


Liao, Zhanfeng, et al. "Spiking NeRF: Representing the Real-World Geometry by a Discontinuous Representation." Proceedings of the AAAI Conference on Artificial Intelligence. Vol. 38. No. 12. 2024.

その他事例

ロボット

IntelのSNNアクセラレータLoihiを活用
四足歩行ロボットの制御や工業用ロボットハンドの制御





Mangalore, Ashish Rao, et al. "Neuromorphic quadratic programming for efficient and scalable model predictive control: Towards advancing speed and energy efficiency in robotic control." IEEE Robotics & Automation Magazine (2024).

Amaya, Camilo, et al. "Neuromorphic force-control in an industrial task: validating energy and latency benefits." arXiv preprint arXiv:2403.08928 (2024).

SNNの現状

- ✓ANNよりも低消費電力で動作可能なネットワークモデルとして様々な応用先が模索されている
- ✓物体検出や拡散モデルなどでは従来のANNよりも低消費電力・低消費エネルギで推論可能
- ✓イベント情報と相性が良く、センサからアクセラレータまでSNNに特化したシステムを構築する取り組みも進められている

目次

1. スパイキングニューラルネットワークの現状
2. 課題と解決への取り組み
   A) 学習則に関する課題
   B) ハードウェアに関する課題
3. まとめ

SNNの課題

学習則が未成熟

スパイクという微分不可能な性質上、誤差逆伝搬法以外の手法で学習する必要あり

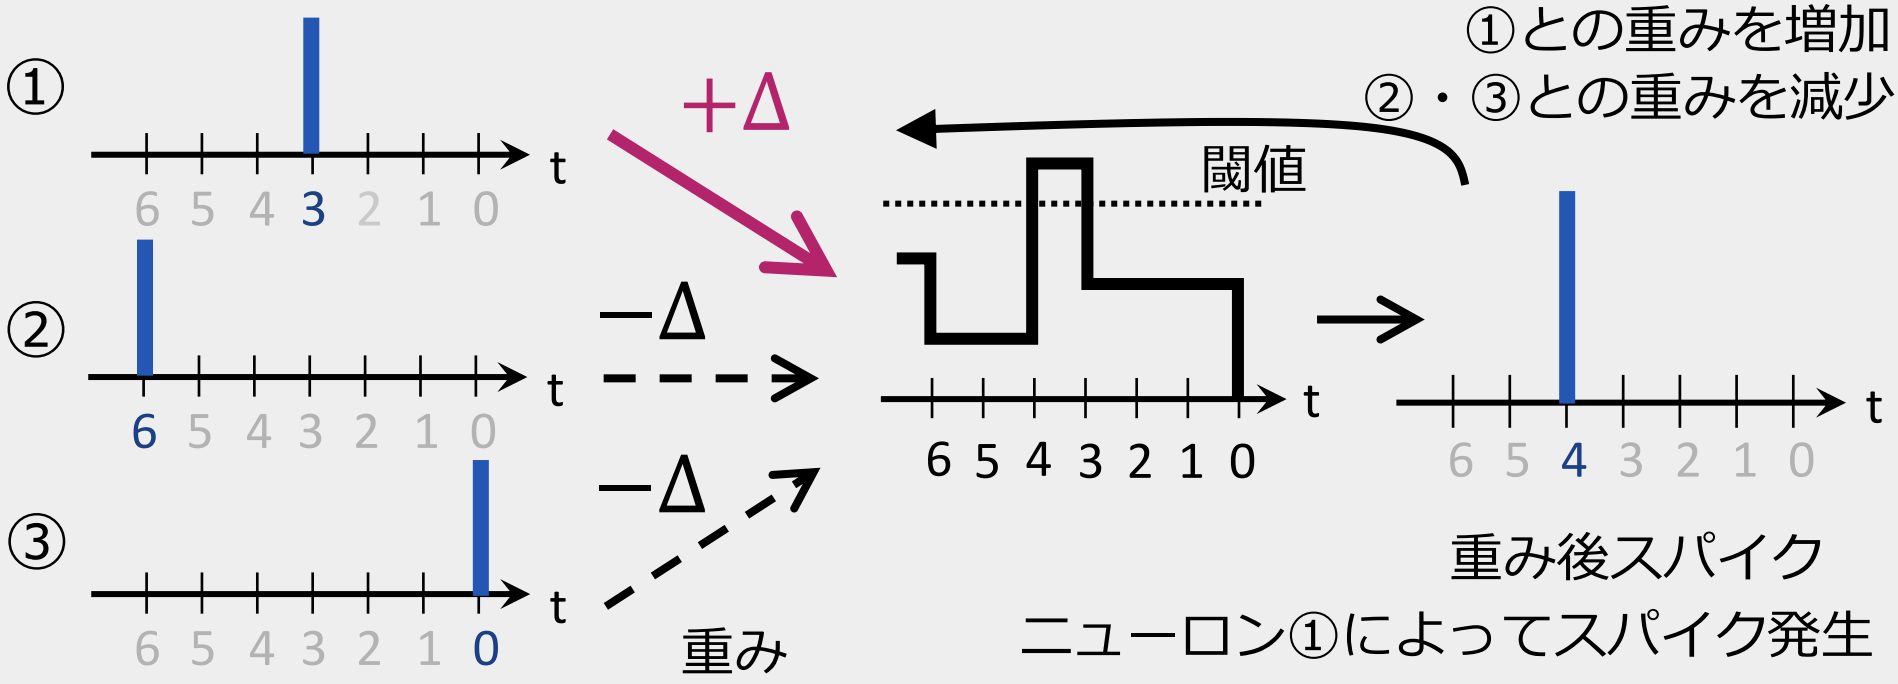
- ✓STDP則
- ✓代理勾配法
- ✓ANN-SNN変換

ハードウェア周りが未成熟

ツールが整備されておらず、学習コストが高い
そもそもハードウェアに改善の余地あり

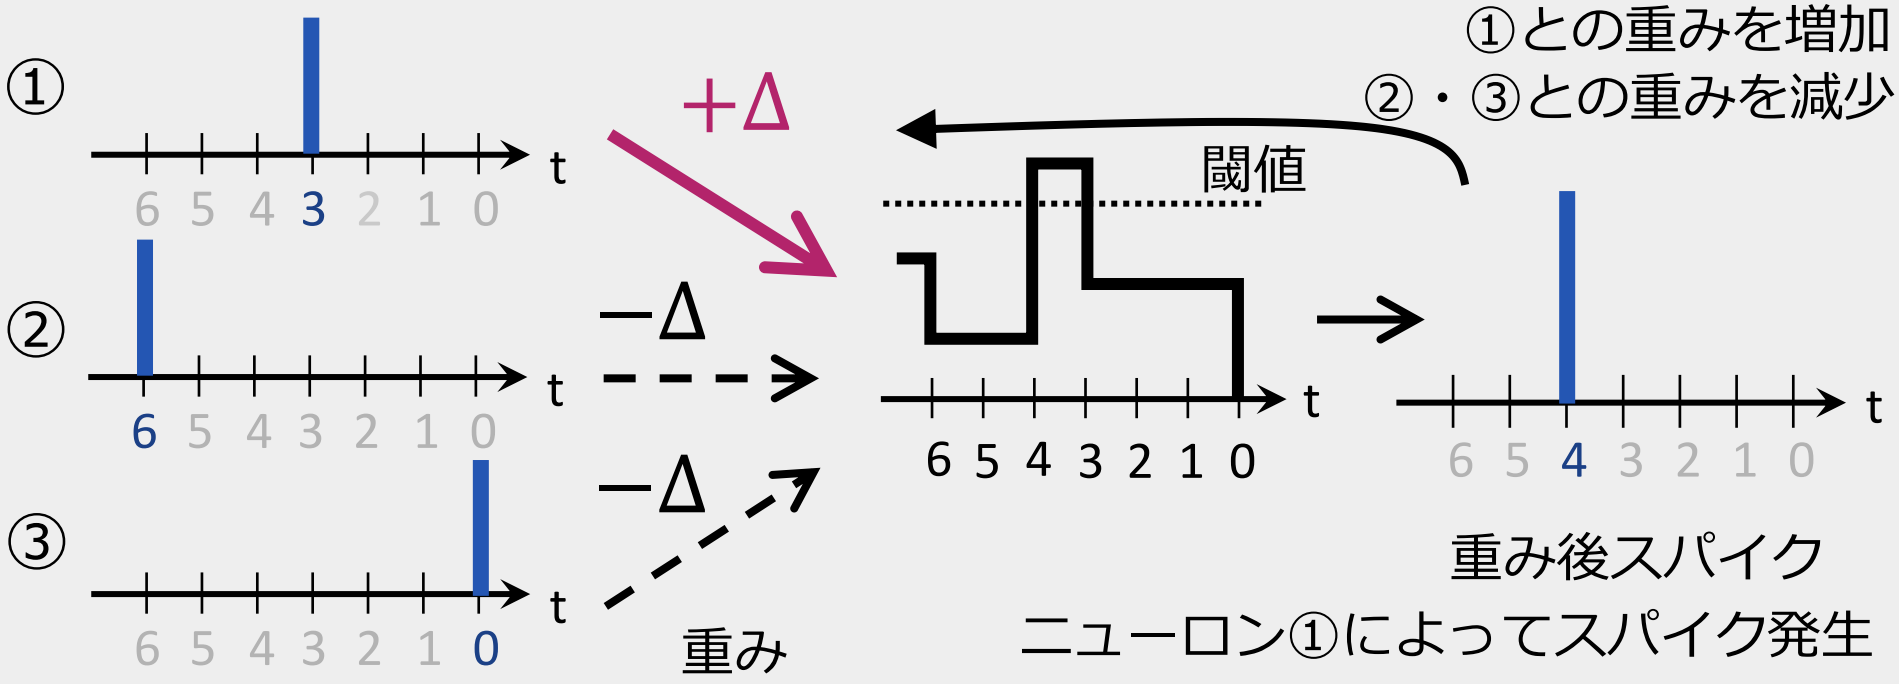
STDP則に関する課題

生体シナプスの重み更新法をモデル化したもので、
二つのニューロン発火タイミングによってその間の
重みを増減させる局所的な学習手法



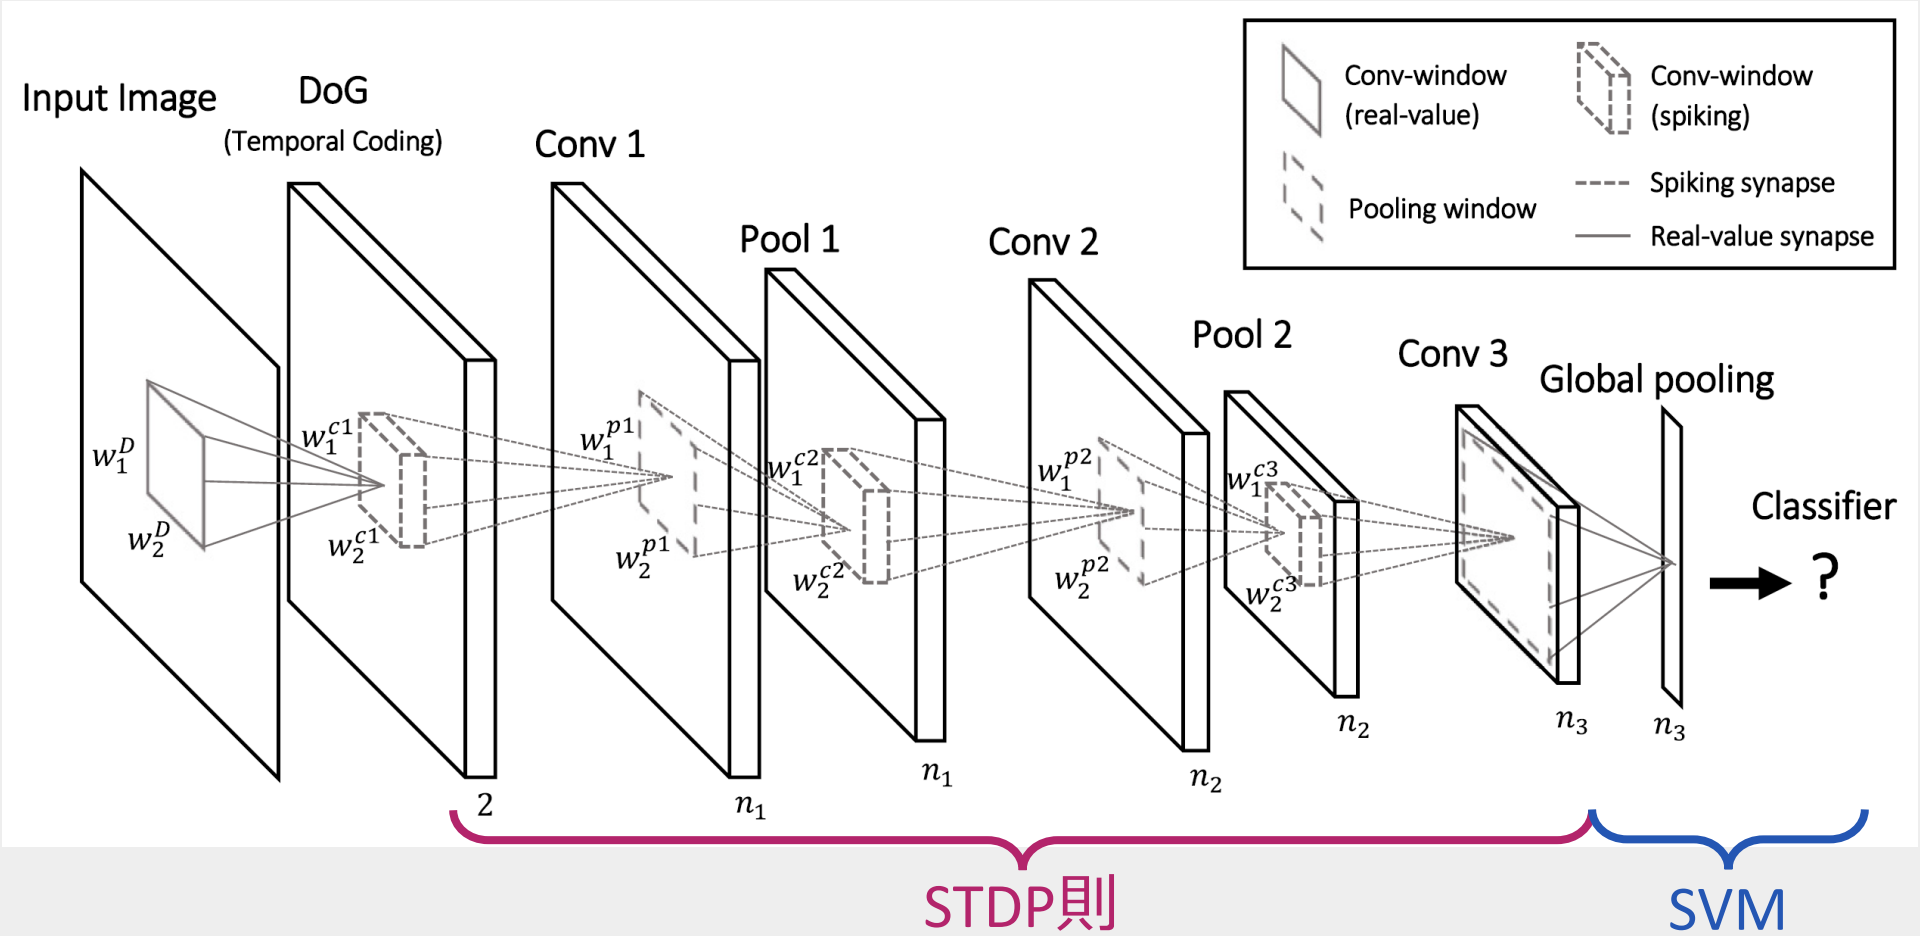
STDP則に関する課題

- ☺ 少ないメモリで学習可能（オンチップ学習可能）
- ☹ 教師信号を伝えることができず、応用先として教師なし学習や強化学習のみに制限



STDP則に関する課題：実施例

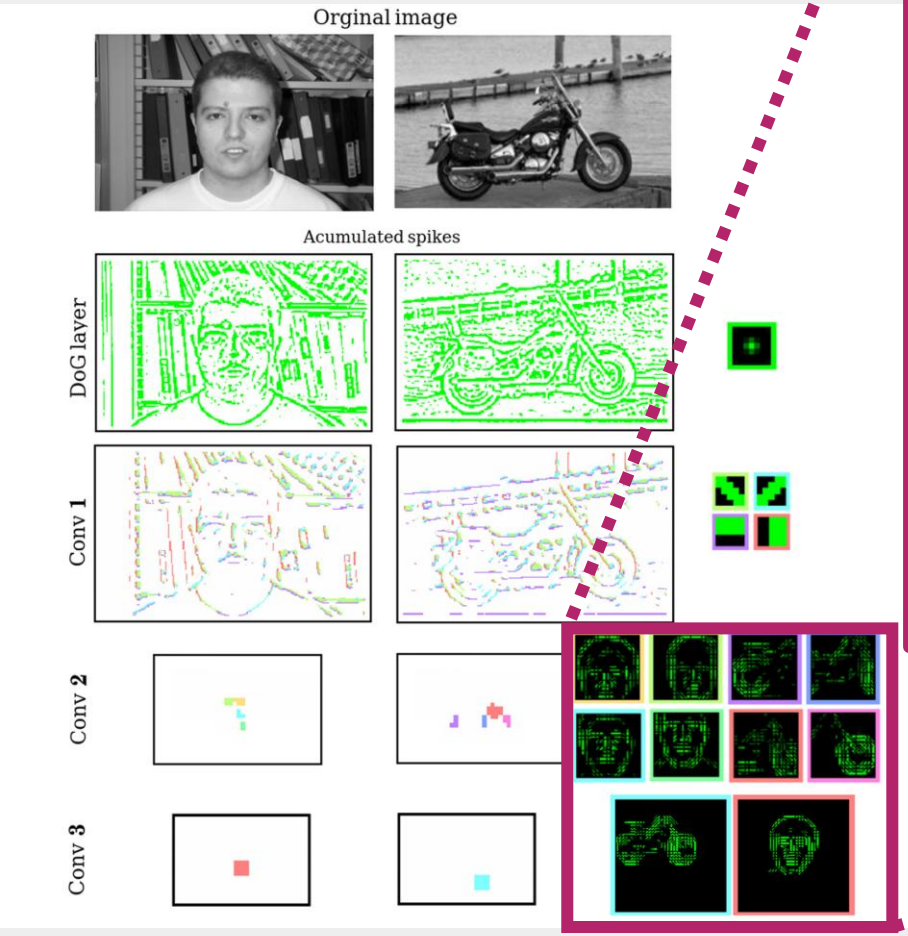
3層の畳み込み層をSTDP則によって学習させ、得られた特徴量をSVMによって分類する実施例

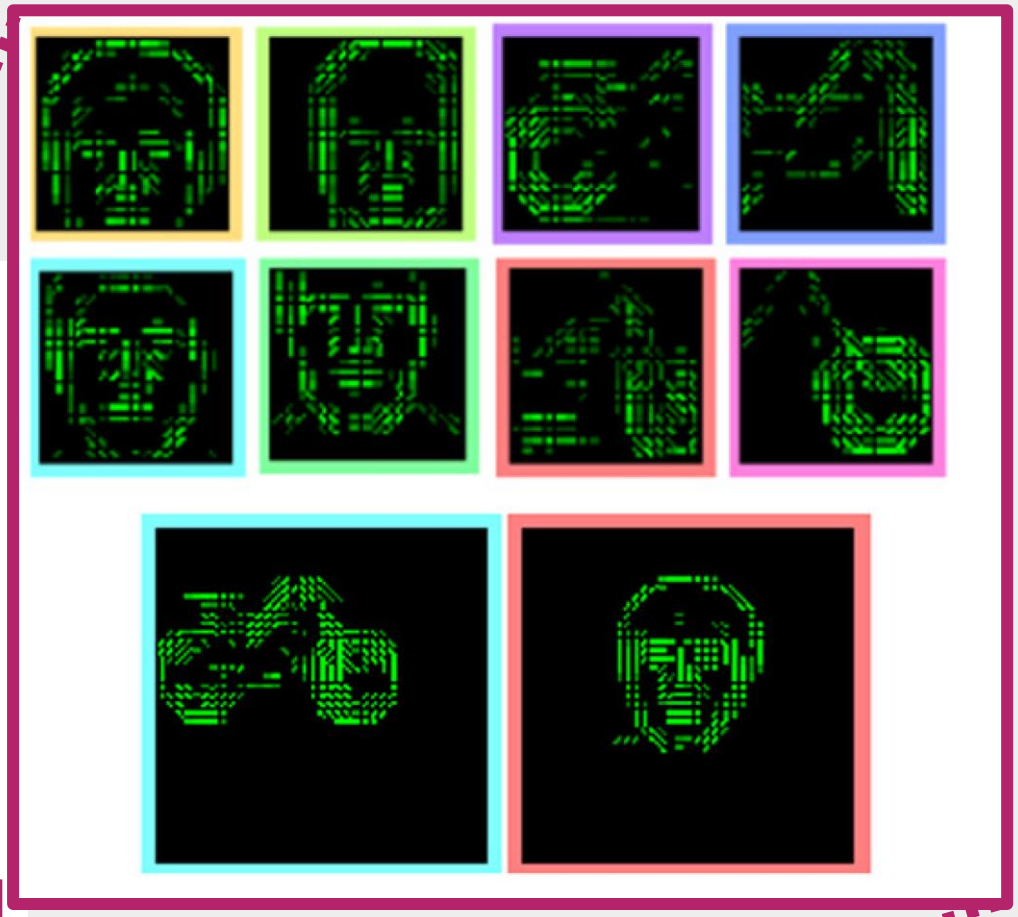


Kheradpisheh, S. R., Ganjtabesh, M., Thorpe, S. J., & Masquelier, T. (2018). STDP-based spiking deep convolutional neural networks for object recognition. Neural Networks, 99, 56-67.

STDP則に関する課題：実施例

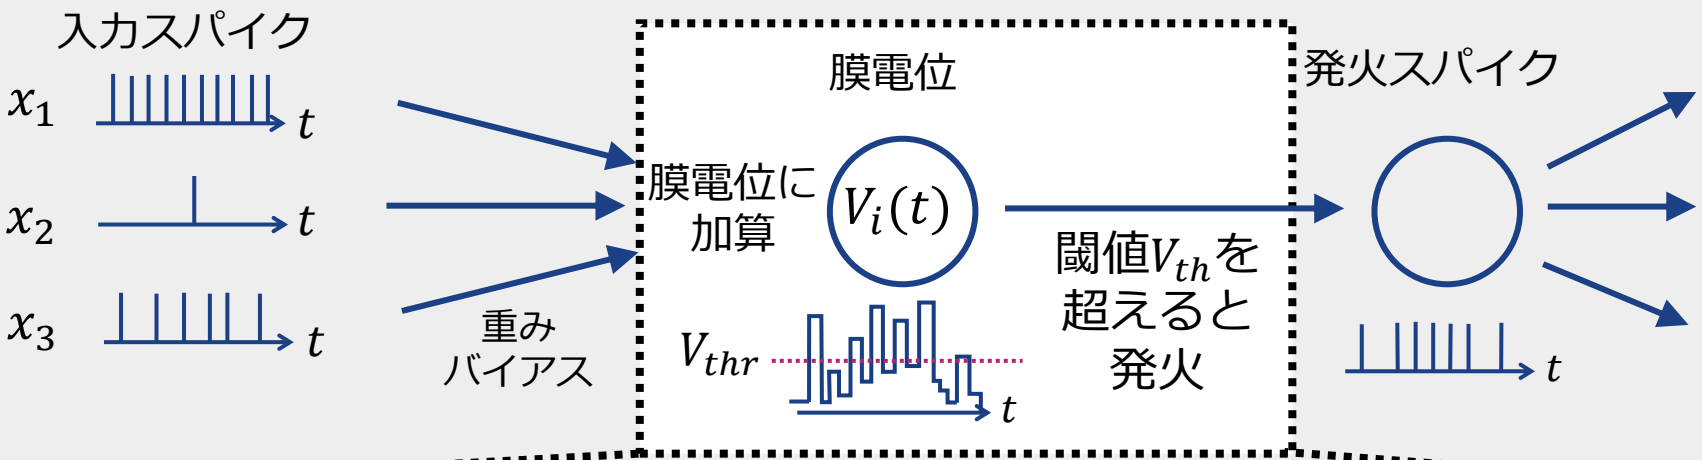
STDP則により学習したカーネルは、対象物の特徴を捉えるような重みに収束

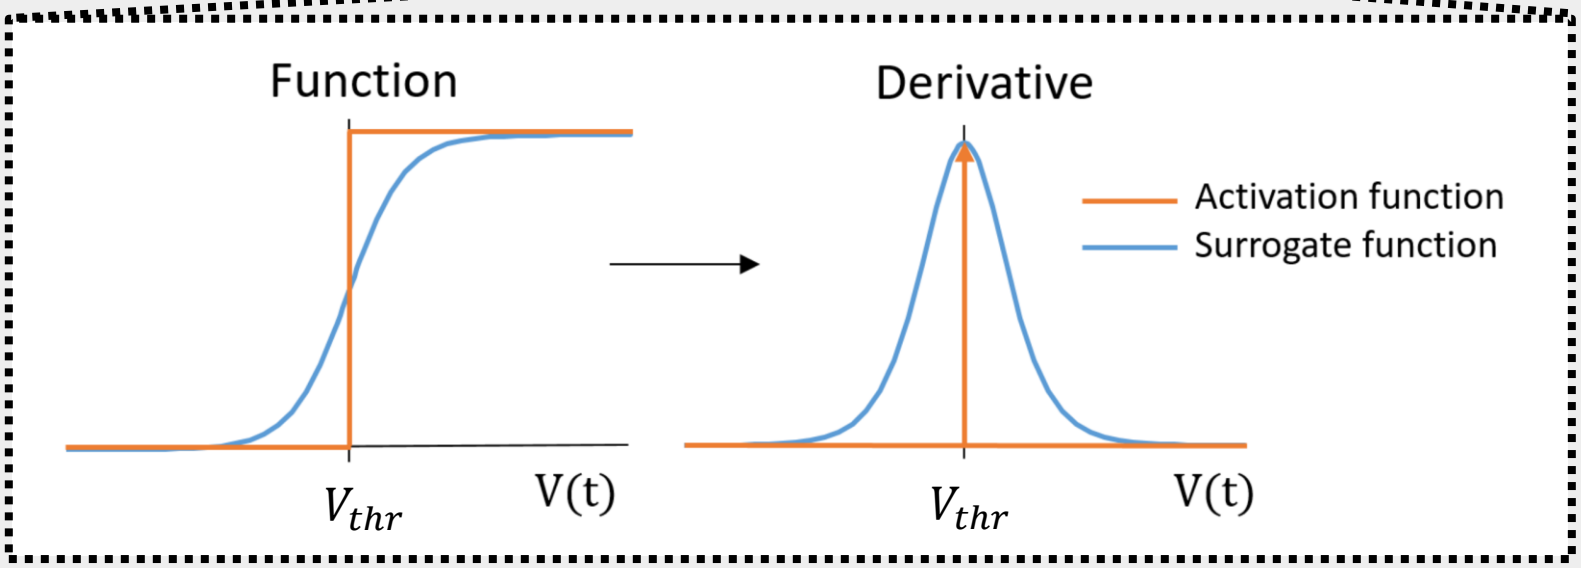




代理勾配法に関する課題

発火の式を勾配計算時のみ微分可能な式に近似し、Backpropagation Trough Timeで学習する手法

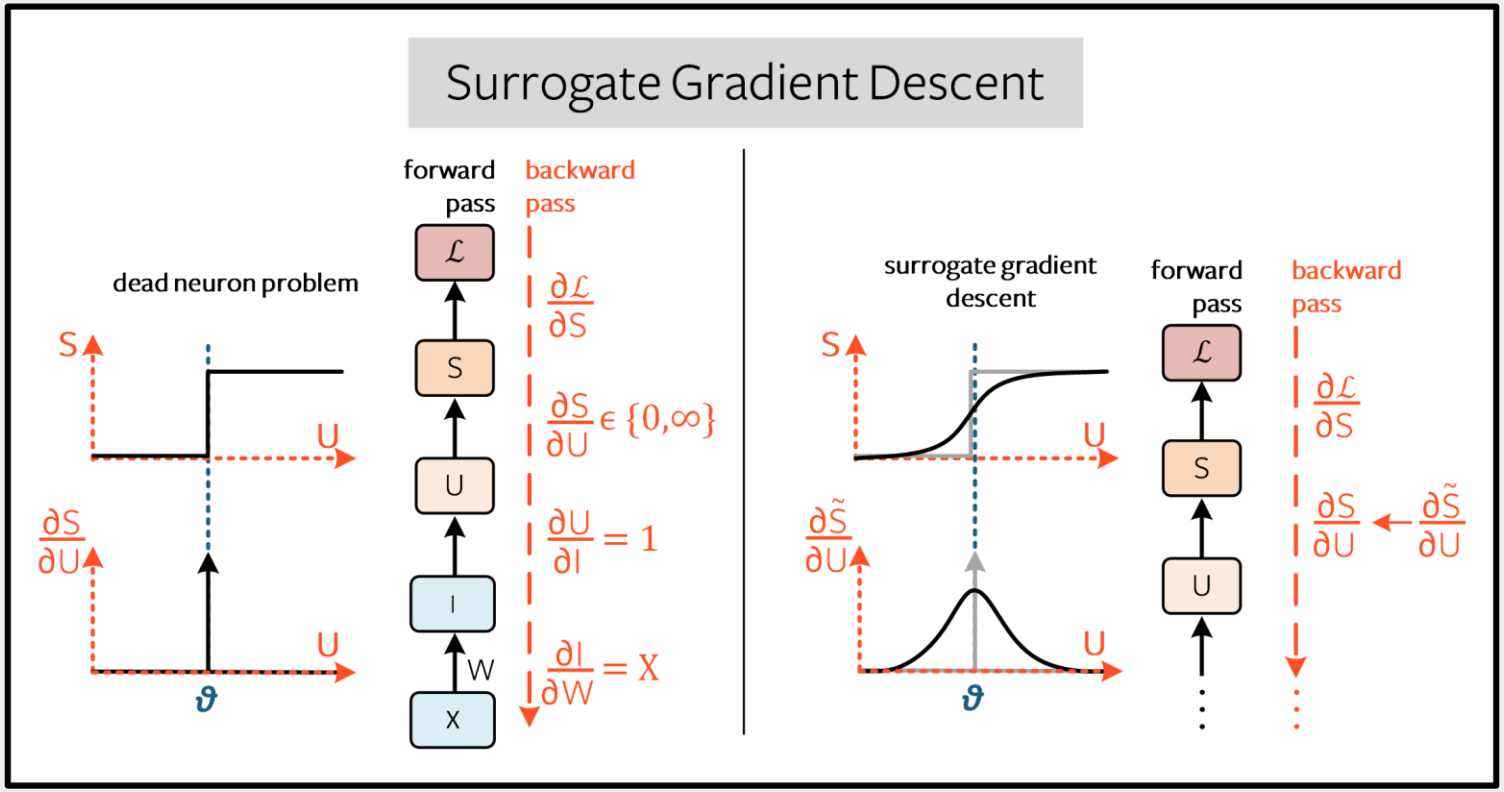




代理勾配法に関する課題

発火の式を勾配計算時のみ微分可能な式に近似し、Backpropagation Trough Timeで学習する手法

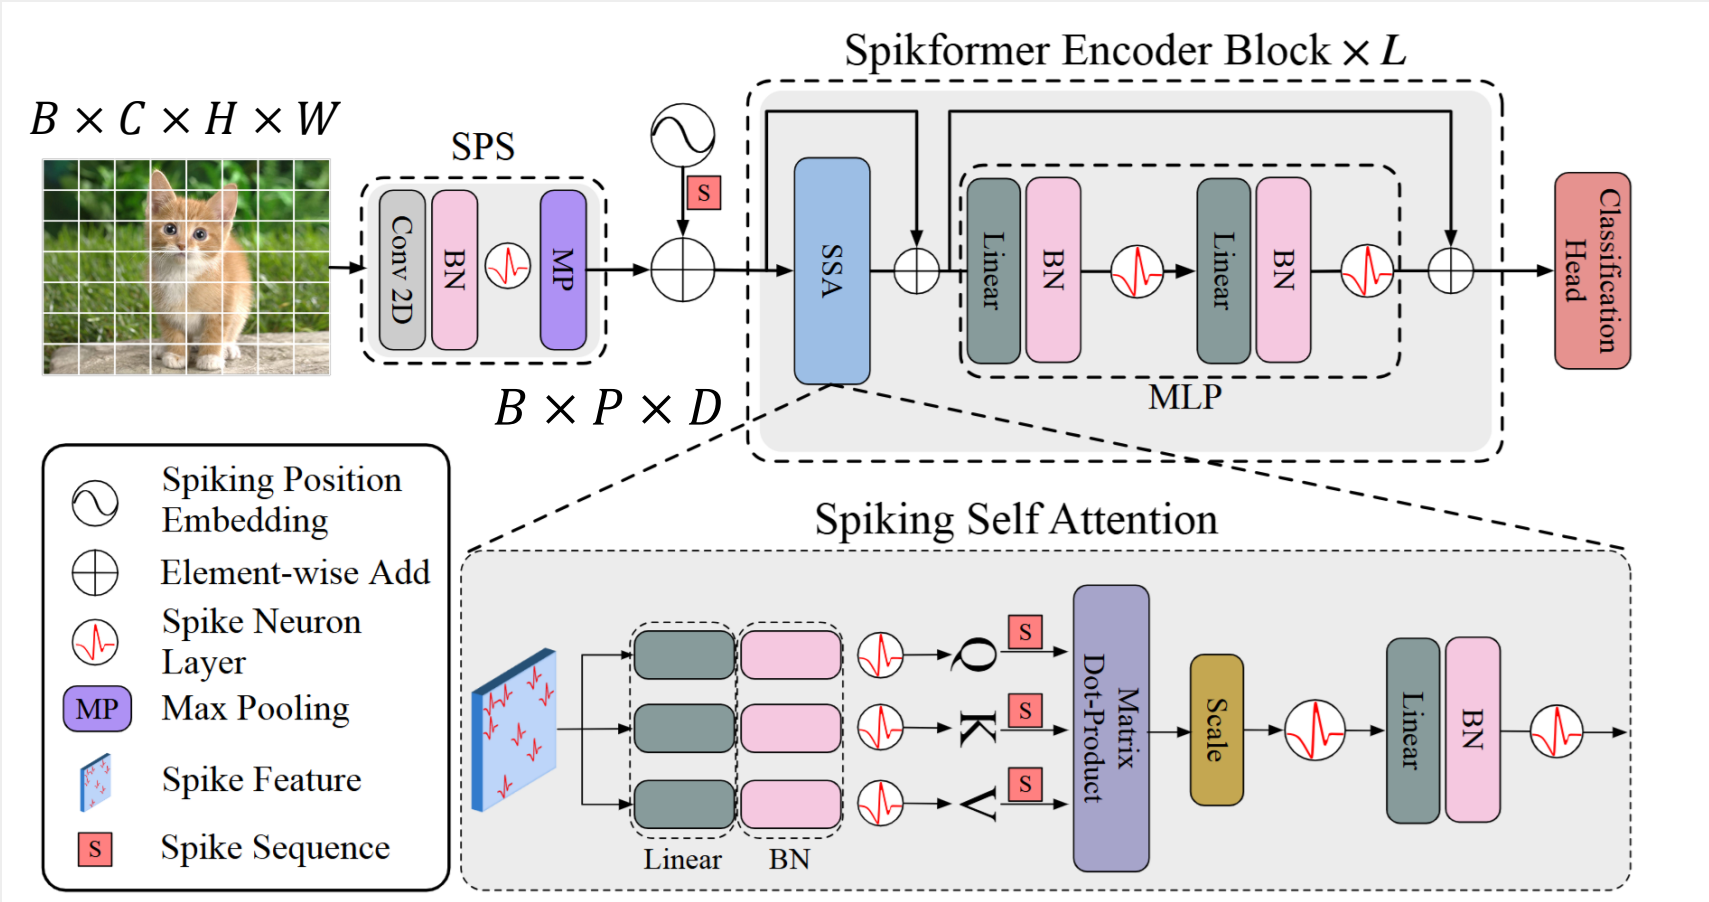
- ☺少ないタイムステップで推論可能
- ☹ ANNと同等の精度に達することが難しい
- ☹学習に十分必要なメモリを確保することが難しい



代理勾配法に関する課題：実施例

Spikfomer

SNNでTransformerを実装したモデルで、スパイクのみでself-attentionを実現できた初めての事例



Zhou, Z., Zhu, Y., He, C., Wang, Y., Yan, S., Tian, Y., & Yuan, L. (2022). Spikformer: When spiking neural network meets transformer. arXiv preprint arXiv:2209.15425.

代理勾配法に関する課題：実施例

Spikfomer

SNNでTransformerを実装したモデルで、スパイクのみでself-attentionを実現できた初めての事例

Methods	Architecture	Param (M)	OPs (G)	Power (mJ)	Time Step	Acc
Hybrid training(Rathi et al., 2020)	ResNet-34	21.79	-	-	250	61.48
TET(Deng et al., 2021)	Spiking-ResNet-34	21.79	-	-	6	64.79
	SEW-ResNet-34	21.79	-	-	4	68.00
Spiking ResNet(Hu et al., 2021a)	ResNet-34	21.79	65.28	59.295	350	71.61
	ResNet-50	25.56	78.29	70.934	350	72.75
STBP-tdBN(Zheng et al., 2021)	Spiking-ResNet-34	21.79	6.50	6.393	6	63.72
SEW ResNet(Fang et al., 2021a)	SEW-ResNet-34	21.79	3.88	4.035	4	67.04
	SEW-ResNet-50	25.56	4.83	4.890	4	67.78
	SEW-ResNet-101	44.55	9.30	8.913	4	68.76
	SEW-ResNet-152	60.19	13.72	12.891	4	69.26
Transformer	Transformer-8-512	29.68	8.33	38.340	1	**80.80**
Spikformer	Spikformer-8-384	16.81	6.82	7.734	4	70.24
	Spikformer-6-512	23.37	8.69	9.417	4	72.46
	Spikformer-8-512	29.68	11.09	11.577	4	**73.38**
	Spikformer-10-512	36.01	13.67	13.899	4	**73.68**
	Spikformer-8-768	66.34	22.09	21.477	4	**74.81**

Zhou, Z., Zhu, Y., He, C., Wang, Y., Yan, S., Tian, Y., & Yuan, L. (2022). Spikformer: When spiking neural network meets transformer. arXiv preprint arXiv:2209.15425.

代理勾配法の課題解決方針

☹ ANNと同等の精度に達することが難しい

✓Optimizerなどのハイパーパラメータの調整する方針

Deng, Lei, et al. "Rethinking the performance comparison between SNNS and ANNS." Neural networks 121 (2020): 294-307.

✓**時間変化も学習する方針**

Deng, S., Li, Y., Zhang, S., & Gu, S. (2022). Temporal efficient training of spiking neural network via gradient re-weighting. arXiv preprint arXiv:2202.11946.

☹学習に十分必要なメモリを確保することが難しい

✓学習済みANNで初期化する方針

Rathi, Nitin, and Kaushik Roy. "Diet-SNN: Direct input encoding with leakage and threshold optimization in deep spiking neural networks." arXiv preprint arXiv:2008.03658 (2020).

✓スパイクの発火時刻で情報を表現する方針

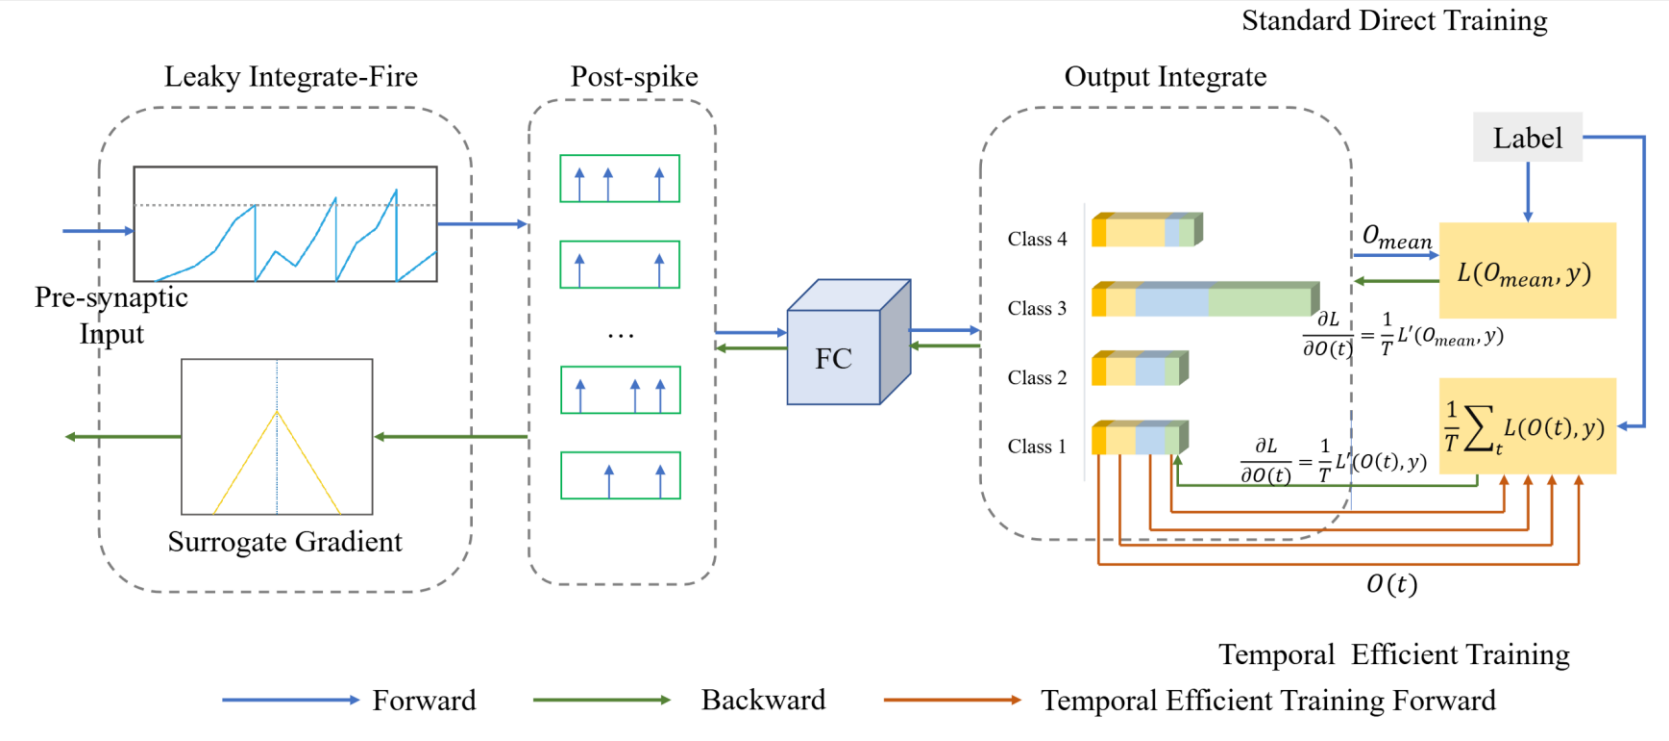
Comşa, Iulia-Maria, et al. "Temporal coding in spiking neural networks with alpha synaptic function: learning with backpropagation." IEEE transactions on neural networks and learning systems 33.10 (2021): 5939-5952.

代理勾配法の課題解決方針

時間変化も学習する方針

例）Temporal efficient training method

推論時間ごとに損失を計算することで、より強い勾配降下を与え、局所最適に陥ることを防ぐ



Deng, S., Li, Y., Zhang, S., & Gu, S. (2022). Temporal efficient training of spiking neural network via gradient re-weighting. arXiv preprint arXiv:2202.11946.

代理勾配法の課題解決方針

小規模なデータセットではANNと同等の精度を達成

Dataset	Model	Methods	Architecture	Simulation Length	Accuracy
CIFAR10	Rathi et al. (2019)	Hybrid training	ResNet-20	250	92.22
	Rathi & Roy (2020)	Diet-SNN	ResNet-20	10	92.54
	Wu et al. (2018)	STBP	CIFARNet	12	89.83
	Wu et al. (2019)	STBP NeuNorm	CIFARNet	12	90.53
	Zhang & Li (2020)	TSSL-BP	CIFARNet	5	91.41
	Zheng et al. (2021)	STBP-tdBN	ResNet-19	6	93.16
				4	92.92
				2	92.34
	our model	TET	ResNet-19	6	**94.50**±0.07
				4	**94.44**±0.08
				2	**94.16**±0.03
	ANN*	ANN	ResNet-19	1	94.97
CIFAR100	Rathi et al. (2019)	Hybrid training	VGG-11	125	67.87
	Rathi & Roy (2020)	Diet-SNN	ResNet-20	5	64.07
	Zheng et al. (2021)*	STBP-tdBN	ResNet-19	6	71.12±0.57
				4	70.86±0.22
				2	69.41±0.08
	our model	TET	ResNet-19	6	**74.72**±0.28
				4	**74.47**±0.15
				2	**72.87**±0.10
	ANN*	ANN	ResNet-19	1	75.35

代理勾配法の課題解決方針

大規模なデータセットでは改善の余地あり

ImageNet	Rathi et al. (2019)	Hybrid training	ResNet-34	250	61.48
	Sengupta et al. (2018)	SPIKE-NORM	ResNet-34	2500	69.96
	Zheng et al. (2021)	STBP-tdBN	Spiking-ResNet-34	6	63.72
	Fang et al. (2021)	SEW ResNet	SEW-ResNet-34	4	67.04
	our model	TET	Spiking-ResNet-34	6	**64.79**
		TET	SEW-ResNet-34	4	**68.00**
	Pytorch公式実装	ANN	ResNet34	1	73.31

https://pytorch.org/vision/main/models/generated/torchvision.models.resnet34.html

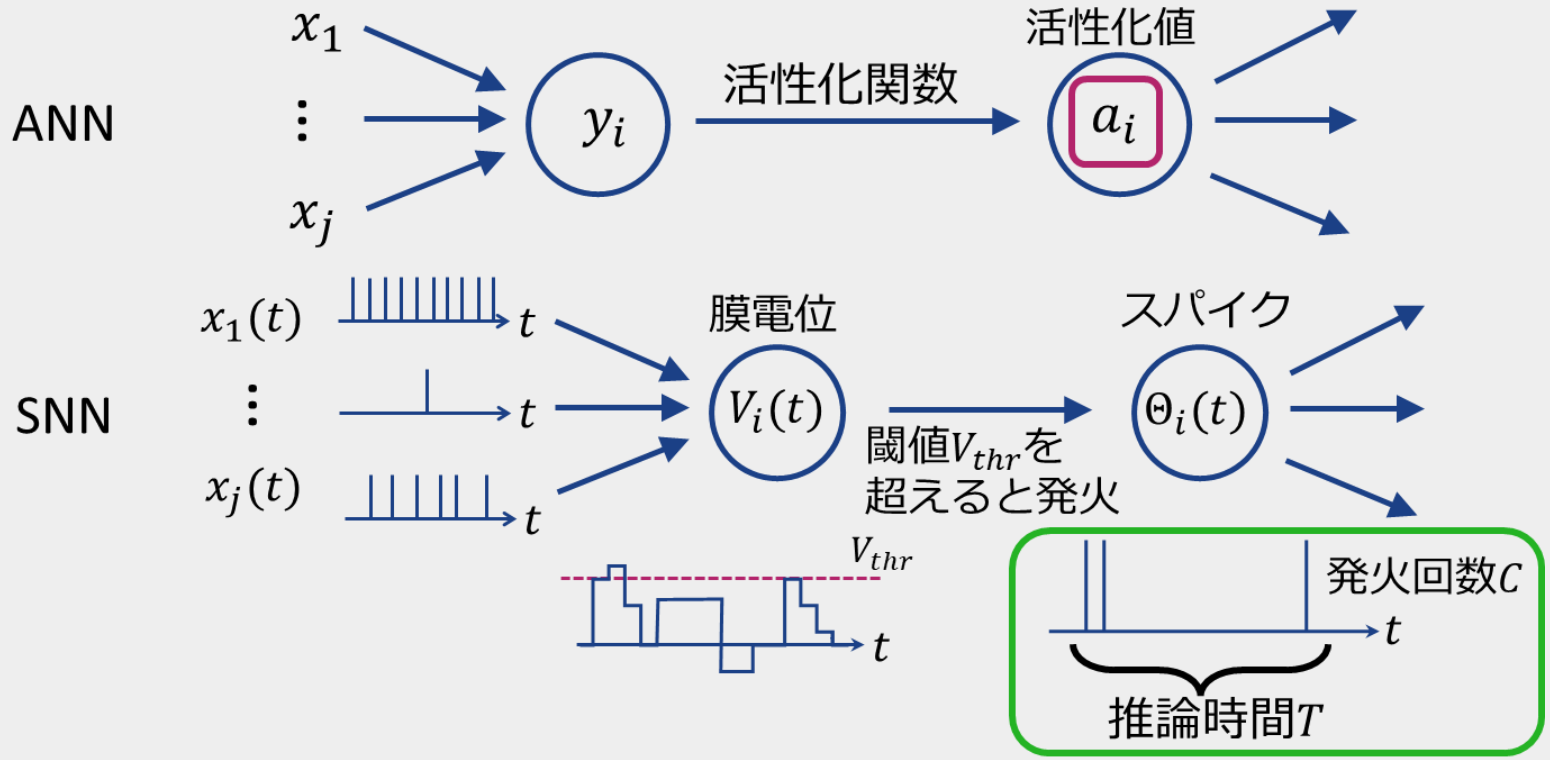
イベント時系列データセットでは最も良い結果

DVS-CIFAR10	Zheng et al. (2021)	STBP-tdBN	ResNet-19	10	67.8
	Kugele et al. (2020)	Streaming Rollout	DenseNet	10	66.8
	Wu et al. (2021)	Conv3D	LIAF-Net	10	71.70
	Wu et al. (2021)	LIAF	LIAF-Net	10	70.40
	our model	TET	VGGSNN	10	**77.33**±0.21
		TET†	VGGSNN	10	**83.17**±0.15

ANN-SNN変換に関する課題

活性化値と発火率を一致させるように学習済みANNをSNNにマッピングする学習手法

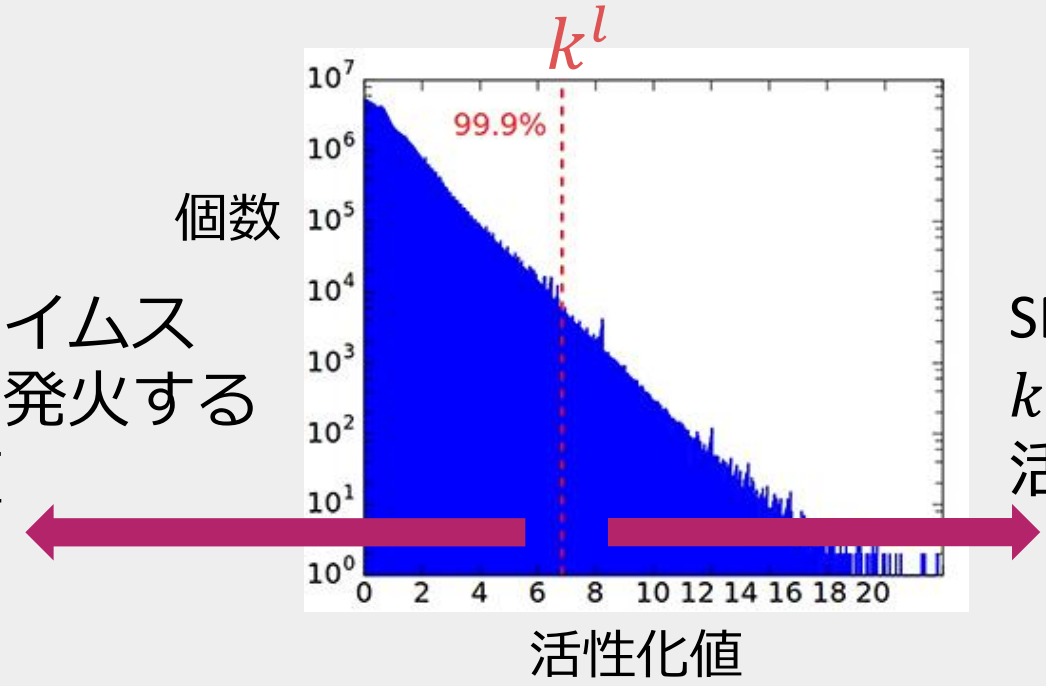
- ☺ 従来のANNモデルと同等の精度を達成可能
- ☹ 莫大な推論時間が必要
- ☹ 変換できないモデル構造がある



ANN-SNN変換に関する課題

重み・バイアスを**ANNの活性化値のうち99.9パーセンタイル値**で正規化

$$\bar{w}_{i,j}^{l} = w_{i,j}^{l} \frac{k^{l-1}}{k^{l}} \qquad \bar{b}_{i}^{l} = b_{i}^{l} \frac{1}{k^{l}}$$



複数のタイムステップで発火する活性化値

SNN側で発火しても、k^lの値に丸められる活性化値

Rueckauer, B., Lungu, I. A., Hu, Y., Pfeiffer, M., & Liu, S. C. (2017). Conversion of continuous-valued deep networks to efficient event-driven networks for image classification. Frontiers in neuroscience, 11, 682.

SNNの学習：ANN-SNN変換

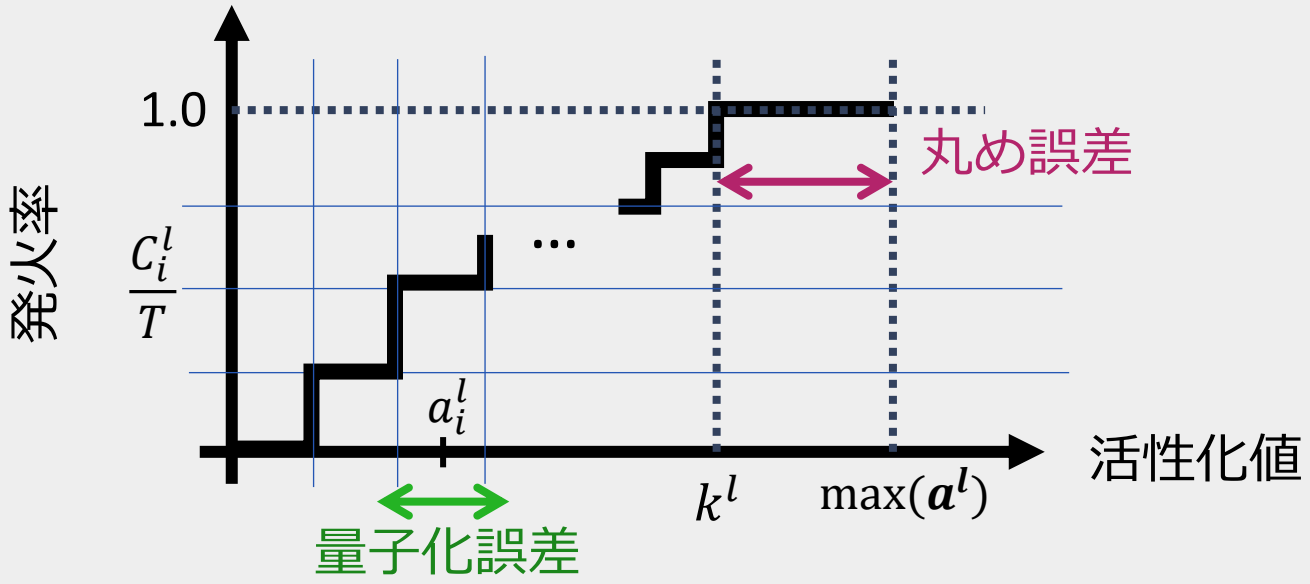
ANN-SNN変換の誤差

- ✓ 丸め誤差

  SNNの発火率で表現可能な値の範囲と元のANNの活性化値で表現可能な値の範囲の差

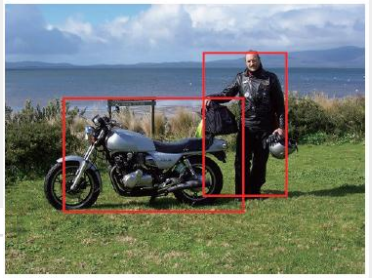
- ✓ 量子化誤差

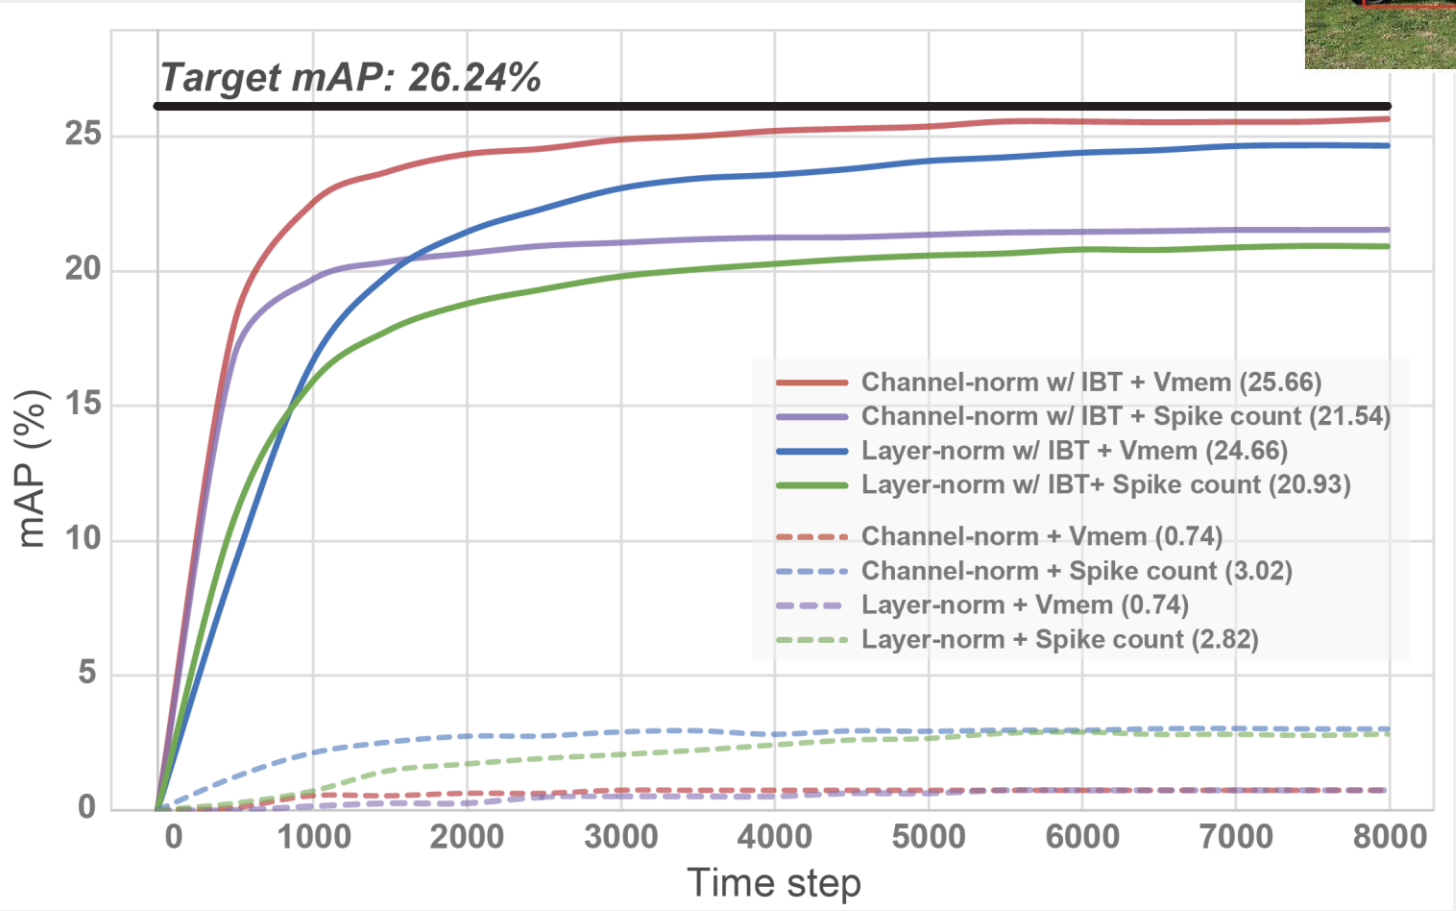
  発火率は離散値であるが活性化値は実数
  推論時間Tを大きくすることで削減可能



ANN-SNN変換に関する課題：実施例

Spiking YOLO（スライド7～10）
数千タイムステップも推論に必要





MS COCOデータセットにおける結果

ANN-SNN変換に関する課題：実施例

ANNの推論時間：0.12 / 250 = 4.8×10^{-4}秒

SNNの推論時間：4.29×10^{-4} / 1.225×10^{-4} = 3.5秒

Tiny YOLO					
	Power (W)	GFLOPS	FLOPs		Energy (J)
	250	14,000	6.97E+09		0.12
Spiking-YOLO					
Norm. methods	GFLOPS / W	FLOPs	Power (W)	Time steps	Energy (J)
Layer	400	5.28E+07	1.320E-04	8,000	1.06E-03
Channel	400	4.90E+07	1.225E-04	**3,500**	**4.29E-04**

ANN: Titan V100で実行したときのパフォーマンス

SNN: TrueNorthで実行したときのパフォーマンス

ANN-SNN変換の課題解決方針

☹ 莫大な推論時間（レイテンシ）が必要

✓変換前の重みや活性化値を量子化する方針

Bu, T., Fang, W., Ding, J., Dai, P., Yu, Z., & Huang, T. (2023). Optimal ANN-SNN conversion for high-accuracy and ultra-low-latency spiking neural networks. arXiv preprint arXiv:2303.04347.

✓膜電位などのハイパーパラメータを調整する方針

Hwang, Sungmin, et al. "Low-latency spiking neural networks using pre-charged membrane potential and delayed evaluation." Frontiers in Neuroscience 15 (2021): 629000.

✓事前知識や出力以外の情報を利用する方針

Habara, Takehiro, Takashi Sato, and Hiromitsu Awano. "BayesianSpikeFusion: accelerating spiking neural network inference via Bayesian fusion of early prediction." Frontiers in Neuroscience 18 (2024): 1420119.

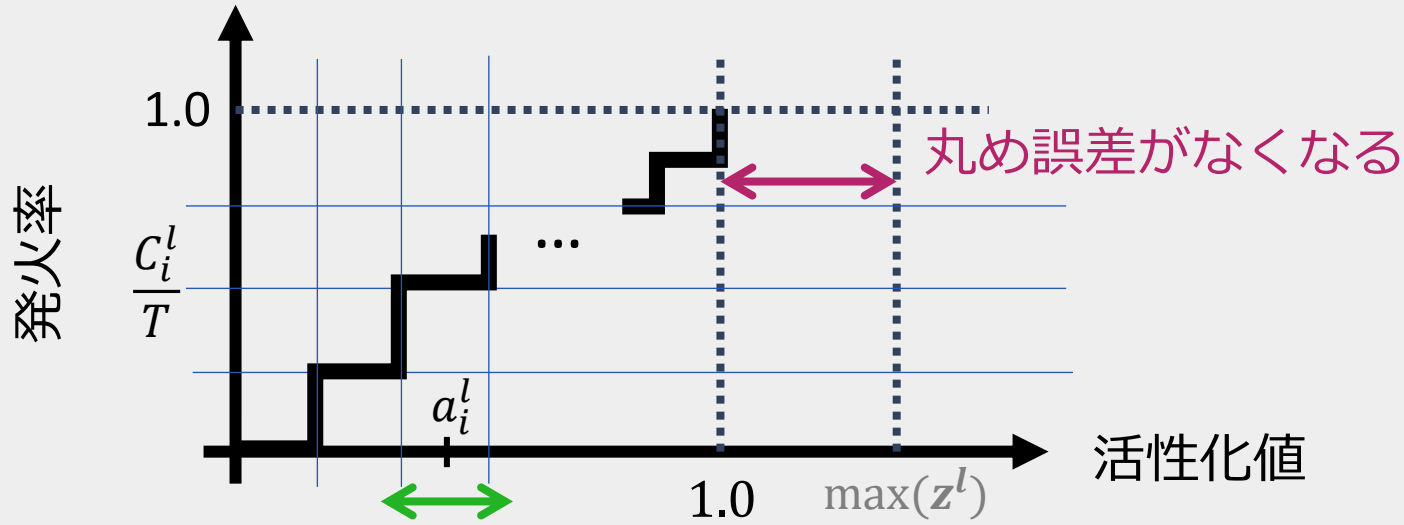
ANN-SNN変換の課題解決

ANNの学習時に活性化値を量子化する手法

例）Quantization clip-floor-shift activation function

ReLU関数の代わりとなる下のような式

$$a^l = \lambda^l \mathrm{clip}\left(\frac{1}{L}\left\lfloor \frac{z^l L}{\lambda^l} + \varphi \right\rfloor, 0, 1\right)$$



床関数により学習時に離散値であることを明示することで量子化誤差を削減

Bu, T., Fang, W., Ding, J., Dai, P., Yu, Z., & Huang, T. (2023). Optimal ANN-SNN conversion for high-accuracy and ultra-low-latency spiking neural networks. arXiv preprint arXiv:2303.04347.

ANN-SNN変換の課題解決

QCFSを用いることで推論時間を大幅に削減

Architecture	Method	ANN	T=16	T=32	T=64	T=128	T=256	T≥1024
ResNet-34	RMP	70.64%	-	-	-	-	-	65.47%
	TSC	70.64%	-	-	-	-	61.48%	65.10%
	RTS	75.66%	-	0.09%	0.12%	3.19%	47.11%	75.08%
	SNNC-AP	75.66%	-	64.54%	71.12%	73.45%	74.61%	75.45%
	Ours	74.32%	59.35%	69.37%	72.35%	73.15%	73.37%	73.39%
VGG-16	RMP	73.49%	-	-	-	-	48.32%	73.09%
	TSC	73.49%	-	-	-	-	69.71%	73.46%
	RTS	75.36%	-	0.114%	0.118%	0.122%	1.81%	73.88%
	SNNC-AP	75.36%	-	63.64%	70.69%	73.32%	74.23%	75.32%
	Ours	74.29%	50.97%	68.47%	72.85%	73.97%	74.22%	74.32%

ImageNetデータセットでの実施例：OursがQCFS

学習則の課題まとめ

	代理勾配法	ANN-SNN変換	STDP則
メリット	✓ 低レイテンシ	✓ 従来のANNと同等の精度	✓ オンチップ学習が可能
デメリット	✓ ANNよりも精度劣化 ✓ 消費メモリが大きい	✓ 高レイテンシ ✓ 複雑なモデル構造の変換は難しい	✓ 教師なし学習や強化学習のみに制限
解決の方針	✓ 時間変化も同時に学習 ✓ スパイクの発火時刻で情報を表現	✓ ANN学習時に活性化関数を工夫 ✓ ハイパーパラメータの調整 ✓ 事前知識などの活用	✓ 他の機械学習モデルと組み合わせる

SNNの課題

学習則が未成熟

スパイクという微分不可能な性質上、誤差逆伝搬法以外の手法で学習する必要あり

- ✓STDP則
- ✓代理勾配法
- ✓ANN-SNN変換

ハードウェア周りが未成熟

ツールが整備されておらず、学習コストが高い
そもそもハードウェアに改善の余地あり

ハードウェアアクセラレータ

ANN

単位時間あたりに多くの行列演算が可能なGPU、TPU

SNN

イベント駆動（非同期）なニューロモーフィックチップ

- ✓ IBM TrueNorth
  初めて作られたニューロモーフィックチップで現在アクセス不可
- ✓ Intel Loihi
  基礎から応用まで利用されている
  研究者のみアクセス可能
- ✓ SynSense SPECK™
  イベントカメラと相性が良く、エッジデバイスとして実用に向けた開発



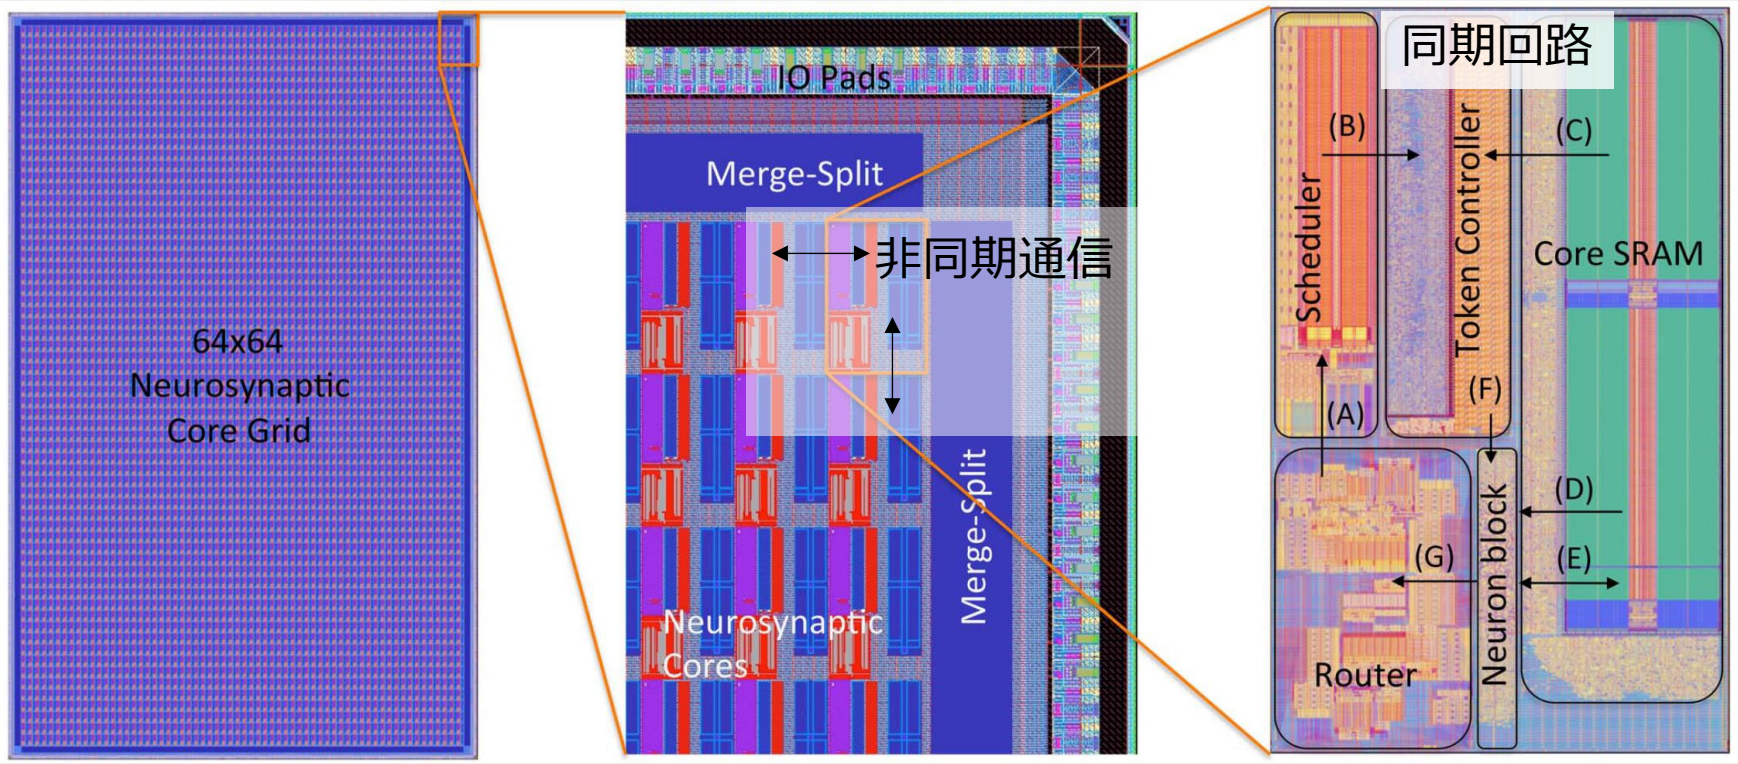
Loihiを大量に積んだサーバ
6ラックユニットで2600W
イベント駆動で15TOPS/W

https://www.intel.co.jp/content/www/jp/ja/newsroom/news/intel-builds-world-largest-neuromorphic-system.html

ハードウェアアクセラレータ

従来のニューロモーフィックチップ

- ✓大域非同期・局所同期方式で実装
  - 重み乗算など要素ごとの回路は消費電力の大きい同期回路
  - 要素間の通信は消費電力の小さい非同期回路



F. Akopyan et al., "TrueNorth: Design and Tool Flow of a 65 mW 1 Million Neuron Programmable Neurosynaptic Chip," in IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, vol. 34, no. 10, pp. 1537-1557, Oct. 2015, doi: 10.1109/TCAD.2015.2474396.

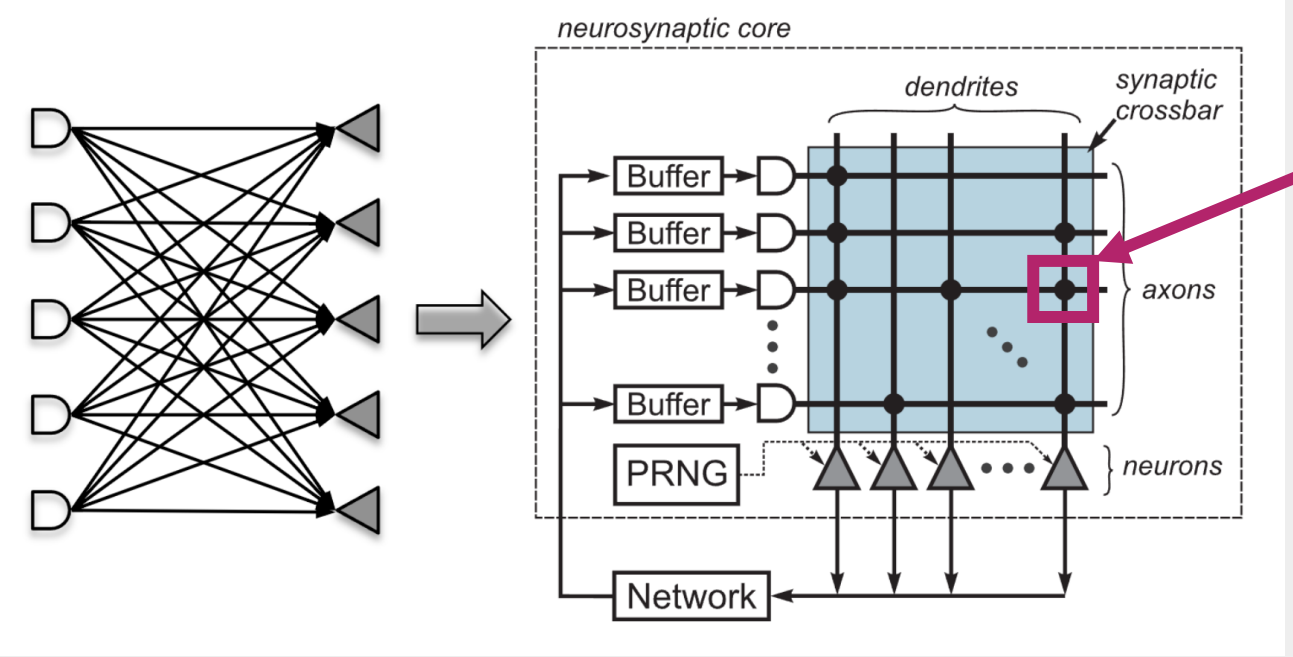
ハードウェアアクセラレータ

従来のニューロモーフィックチップ

✓コンピューティングインメモリ(CIM)の採用

計算回路とメモリを融合させることでメモリボトルネックを解消

メモリにはSRAMを採用



重みが保存されているSRAM

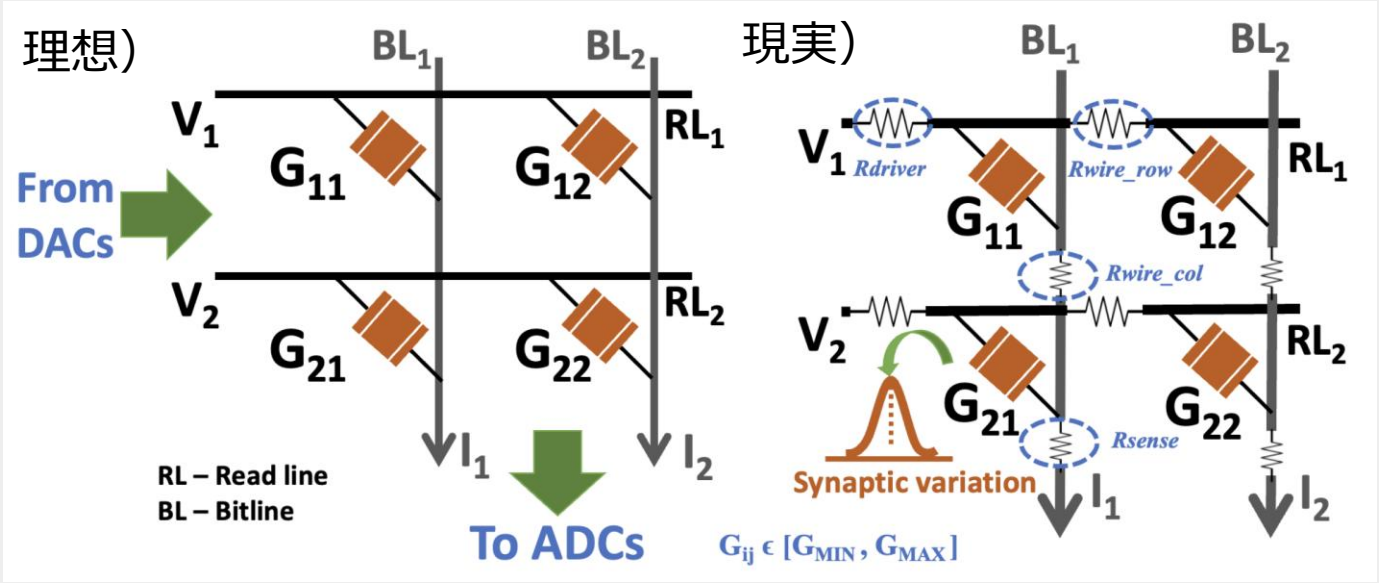
☹SRAMは揮発性で、データを再度書き込む必要あり

☹回路面積/消費電力/レイテンシの削減余地あり

ハードウェアアクセラレータ

現在目指されているニューロモーフィックチップ

- ✓CIMで採用するメモリとして不揮発性メモリの採用
  - 抵抗値として値を保存可能な抵抗変化型メモリ（RRAM）や相変化メモリ（PCM）



☹ このような不揮発性メモリはノイズや配線抵抗の影響を受けやすく、推論時に理想的な値から大きく変動してしまう

Abhiroop Bhattacharjee, Youngeun Kim, Abhishek Moitra, and Priyadarshini Panda. 2022. Examining the Robustness of Spiking Neural Networks on Non-ideal Memristive Crossbars. In Proceedings of the ACM/IEEE International Symposium on Low Power Electronics and Design (ISLPED '22). Association for Computing Machinery, New York, NY, USA, Article 1, 1–6. https://doi.org/10.1145/3531437.3539729

ハードウェアの課題解決方針

- ✓Write-Verify
  - 重みの値が理想的な値となるように一つ一つ確認する手法
  - しかし、確認するための人的コストが大きい
- ✓補正回路を導入する方針
  - 正解データを保持し、定期的に重みと正解データを比較して補正する
  - しかし、回路のオーバーヘッドが大きい
- ✓Noise-aware学習
  - 学習時に使用するデバイスの特性を明らかにして学習
  - ノイズモデルが対象デバイスごとに異なり、汎用性がない

ハードウェアの課題まとめ

一般的な課題として…

- ✓ツールなどが未成熟なため学習コストが高い
- ✓非同期に通信を実施するため既存のシステムとの統合が難しい

	従来チップ	次世代チップ
回路面積	大きい	小さい
消費電力	大きい	小さい
レイテンシ	大きい	小さい
精度	高い	低い

目次

1. スパイキングニューラルネットワークの現状
2. 課題と解決への取り組み
3. まとめ
   A) 現状のまとめ
   B) 課題とその解決方針のまとめ

まとめ：現状

SNNの現状

- ✓ANNよりも低消費電力で動作可能なネットワークモデルとして様々な応用先が模索されている
- ✓物体検出や拡散モデルなどでは従来のANNよりも低消費電力・低消費エネルギで推論可能
- ✓イベント情報と相性が良く、センサからアクセラレータまでSNNに特化したシステムを構築する取り組みも進められている

まとめ：課題と解決方針

✓学習：STDP則

オンチップ学習が容易だが、応用先が制限される

他の機械学習モデルと組み合わせていく必要あり

✓学習：代理勾配法

推論時間が短いが、低精度であり学習コストも高い

損失関数やスパイク表現の方式を工夫する必要あり

✓学習：ANN-SNN変換

従来のANNと同等の精度を達成できるが、高レイテンシで複雑なモデル構造の変換は難しい

新たな活性化関数や事前知識を導入する必要あり

✓ハードウェア

ツールなどが未整備で学習コストが高い

抵抗値をメモリとしたハードウェアは回路面積・レイテンシ・消費電力が改善されるが、ノイズによって値が変動しやすく精度が低い

学習から推論のうちどこかで補正をする必要あり

その他

今後、以下のレポジトリに機械学習向けのSNNの資料を作成していきます。

Github: https://github.com/hanebarla/SNN-tutorial